

# 前沿技术专题研究报告

## 合成数据

### Synthetic Data

#### ——技术成熟度评估与银行数据供给体系应用 路径研究——

编制部门：科技发展部

报告版本：V4.3

编制日期：2026 年 9 月

## 一、执行摘要

合成数据（Synthetic Data）指不直接来自真实业务事件、而由生成算法（GAN、VAE、扩散模型、大语言模型及统计合成方法）按真实数据的统计规律“制造”出来的数据。它对准的是一组银行长期存在的矛盾：AI 模型需要足量、多样、及时的训练与测试数据，而真实数据的采集成本高、长尾事件样本稀缺、个人信息合规约束趋严。Gartner 自 2022 年将合成数据列入《数据与分析领域顶级趋势》以来持续跟踪，其口径包括“到 2030 年前后合成数据将在 AI 模型所用数据中超过真实数据”<sup>[18][19]</sup>，以及“到 2026 年，75% 的企业将使用生成式 AI 创建合成客户数据”<sup>[20]</sup>；2025 年又提出“超合成数据（Hyper-Synthetic Data）”将在未来 5—10 年重塑 AI 服务供给<sup>[22]</sup>。产业侧出现了两起标志性并购——NVIDIA 收购合成数据公司 Gretel（2025 年 3 月，报道金额超过 3.2 亿美元）<sup>[23][24]</sup>，SAS 收购 Hazy 核心软件资产（2024 年 11 月）<sup>[25]</sup>，表明基础设施与数据分析厂商开始把合成数据能力并入自身栈。

本报告的结论是：方向值得系统研究并尽快启动小规模验证，但当下不宜作为独立平台立项建设。综合六维评估，建议处置档位为“深入研究（研究层）”——先以“组件化能力+两个场景 POC”切入，用 6 个月拿到可度量的证据后再决定是否升级为系统论证（论证层）。按 GVR、Mordor、Fortune

Business Insights 等机构口径，2025—2026 年市场约在 5 亿—10 亿美元量级、主流预测 2030 年约 18 亿—35 亿美元<sup>[26][27][28][30]</sup>；银行领域的合成数据生产级案例仍然稀少，多数属试点、概念验证与研究合作；国内尚未检索到银行官方披露的规模化生产部署。

综合研判，合成数据在银行的价值应理解为“真实数据提供真实性与权威性，合成数据提供充足性、多样性与可控性”，二者不是替代而是互补，共同构成银行数据资产与 AI 数据工程体系的组成部分。这一判断的证据基础在本报告第三、四章展开：作为通用数据合成技术，其图像、3D 仿真与软件测试子域已相对成熟；但银行主战场——金融表格数据的高保真合成与隐私保护——仍处于工程化早期，且“合成数据 $\neq$ 天然隐私安全”，须叠加差分隐私与对抗性审计方能成立（第五章）。

价值判断上，四类场景的成熟度明显分层（详见第四章场景矩阵）：其一，测试数据生成与系统验证最为成熟，行业验证充分，是 POC 首选；其二，风控与反欺诈模型训练的小样本/长尾数据增强，已有学术证据表明可提升召回等指标<sup>[17]</sup>，但银行生产环境证据稀少，须以真实测试集上的 AUC/KS/召回对比作为验收标准；其三，以合成数据支撑内部与跨机构数据共享，方向合理、但公开证据与监管认可仍不足；其四，面向大模型语料与评测的合成数据属新趋势，处于更早期。本报告

效益测算（第四章表）均为示意区间并标注了依据强度，非收益承诺。

制约因素同样明确（第五章、第七章）：监管侧无专门针对“合成数据”的正面认可条款，其生成端对真实个人信息的处理仍落入《个人信息保护法》《数据安全法》《银行保险机构数据安全管理办法》与算法治理规则的适用范围<sup>[37][38][39][41][42][43]</sup>；技术侧存在保真度—隐私—效用之间的权衡、模式崩溃、偏差放大与模型崩溃（model collapse）<sup>[15]</sup>等固有风险；组织侧的主要约束是复合型人才不足与质量评估方法未标准化。上述风险均有可行的前置管控手段，不触发“无可行前置管控”的单列否决，但决定了现阶段只能以受控试点方式推进。

就我行而言，合成数据与“数智化”战略下的数据管理体系、数据要素价值释放方向一致，属 AI 数据基础设施的技术路径之一；但我行通过《人工智能实施行动计划（2026）》将 AI 能力建设提升至战略核心地位，明确以打造“金融垂类大模型与智能体”为 AI 建设主线（2025 年年报），合成数据未被列入该计划点名的核心建设对象，战略匹配度评 3 分（第七章）。综合六维评分——技术成熟度 3 分、战略匹配度 3 分、价值贡献度 3 分、引入可行度 3 分、战略紧迫度 3 分、生态开放度 4 分——按处置档位映射规则，多个维度处于 3 分附近的关键不确定、趋势明确但尚待判明，指向

“深入研究（研究层）”；战略紧迫度 3 分，在层内优先排期。

落地路径上，以“工具测评→场景 POC→组件化沉淀”为主线：0—6 个月完成开源工具链（SDV、CTGAN/TVAE、ydata-synthetic 等）与商用方案的测评，启动“测试数据生成”与“风控小样本增强”两个 POC，建立含真实测试集的评价基线；6—18 个月在质量（保真度/效用/隐私）评估、差分隐私与成员推断攻击审计、模型风险管理纳入等方向形成行内规范，视 POC 结果决定是否进入有限试点；18—36 个月将能力组件化嵌入数据中台与 AI 平台，支持自助式、配置化生成。核心方法论（质量评估与评测基准）自研，算法层复用开源、按需采购商用差分隐私引擎，避免对单一厂商形成依赖（第九章）。须说明：本报告所有效益区间与场景量化均为示意性参考，非收益承诺，实际以 POC 实测为准；研究方法、评级口径、名词解释与参考文献见附录一至三。

## 二、背景与现状

### （一）合成数据为什么在当下重新受到关注

合成数据并非新概念，统计合成、多重插补等方法可追溯至二十世纪八九十年代（详见第三章演进时间线）。它之所以在 2023—2026 年间进入银行科技视野，是三股力量在同一时间点交汇的结果。

**第一，**AI 对数据的渴求与真实数据供给瓶颈的矛盾到达临界。模型效果高度依赖训练数据的规模、多样与时效。Gartner 的口径是，AI 与分析项目所用数据中合成占比已由 2021 年的约 1% 升至 2024 年的约 60%（该口径为行业估算且含广泛定义，宜作趋势信号而非精确测量）<sup>[19][21]</sup>。更深层的原因是高质量人工生成数据的增长正在放缓，而模型持续需要更多数据；学术界同时警示，若直接以模型自身输出递归训练，可能出现“模型崩溃”——数据多样性与质量逐代退化<sup>[15]</sup>。这一“真实的互联网语料逼近上限、自我生成数据存在退化风险”的语境，使“受控、可溯源、高质量”的合成数据被重新审视，也解释了为何 2025 年 Gartner 提出超合成数据（Hyper-Synthetic Data）概念，主张以仿真、智能体与环境模型生成“现实中难以采集”的数据<sup>[22]</sup>。相关证据还来自微软 2025 年对合成语料缩放规律的实证研究：合成数据在语言模型预训练中呈现可预测的缩放关系，可规模化补充真实语料，但其性能增益存在平台期（约 300B token 后趋缓），提示“以合成补数据”确有其效、但收益有边界<sup>[53]</sup>。

**第二，**隐私监管趋严与数据共享需求的矛盾加剧。国内《个人信息保护法》《数据安全法》及金融监管总局《银行保险机构数据安全管理办法》等要求银行对个人信息与重要数据实行分类分级、最小必要、知情同意管理<sup>[37][38][39]</sup>，真实客户数据在行内部门之间、集团子公司之间、与外部机构之间的流转

成本显著上升。银行业同时面临征信、反欺诈、联合建模等真实的数据协作需求。合成数据被寄望于提供“不指向真实个人、仍保留统计可用性”的数据形态，成为合规语境下的可选项。

第三，生成式 AI 显著降低了数据合成的门槛。扩散模型、大语言模型使文本、表格与多模态数据的生成质量大幅提升，生成工具的工程化程度（开源合成库、托管 API、评测指标）快速成熟<sup>[3][5][6][20]</sup>。Gartner 预计到 2026 年 75% 的企业将使用生成式 AI 创建合成客户数据（2023 年该比例不足 5%）<sup>[20]</sup>。对银行而言，这不再只是研究人员的学术工具，而已成为可评估、可采购、可嵌入现有数据工程链路的工程选项。

（二）银行现有数据供给方式的具体失效机制

判断一项技术值不值得投入，要看它对准的痛点是否真实存在、以及既有方式为什么解决不了。银行数据供给现状并非“数据不够”，而是“合用的数据不够”，具体失效机制有四类，其业务后果如下表所示。

表 1 银行数据供给既有方式的失效机制与业务后果

| 失效机制            | 具体表现                         | 典型业务后果                         | 与合成数据的对应关系             |
|-----------------|------------------------------|--------------------------------|------------------------|
| 真实数据<br>采集慢、标注贵 | 违约、欺诈、流失等事件需多年自然积累；人工标注成本高、口 | 新客群建模与新产品风控模型上线周期长；模型迭代追不上业务变化 | 按需、条件化生成可缩短样本积累周期（需验证） |

| 失效机制        | 具体表现                           | 典型业务后果                            | 与合成数据的对应关系                              |
|-------------|--------------------------------|-----------------------------------|-----------------------------------------|
|             | 径不一                            |                                   |                                         |
| 长尾与极端样本天然稀缺 | 欺诈率、违约率通常远低于 1%；极端市场情景无历史样本    | 模型对高风险长尾识别率低；压力测试情景覆盖不足           | 合成少数类样本增强是学术上相对成熟的路径 <sup>[7][17]</sup> |
| 脱敏/匿名化破坏可用性 | 掩码、泛化、置换破坏字段关联与分布形态，且重识别风险未根除  | 脱敏后的数据“能用不敢用、敢用不好用”，测试与建模效果打折     | 以“生成”替代“改造”，在分布层面重建数据（第三章第五节详析）         |
| 真实数据流转受合规约束 | 个人信息流转需逐项授权；子公司、外部机构间共享审批重、周期长 | 联合建模、科研合作、供应商测试大量依赖“人工造数”，效率低、口径乱 | 合成数据可作为不指向真实个体的共享介质（方向性价值，证据有限）         |

需要指出，第四类“人工造数”是银行当前普遍的现实替代方案：开发测试环境的数据构造长期依赖手工造数工具与业务专家经验。这类方案并非不可用，但其质量取决于专家经验、难以覆盖边界条件、不可规模复用，且缺乏统计口径一致性——这正是测试数据生成场景的痛点来源。

### （三）行业热度与银行落地条件的差距

有必要先把“行业关注度”与“银行业成熟度”分开，避免被市场热度误导。可观测的热度信号包括：Gartner 的三条预测口径——“到 2030 年前后合成数据将在 AI 模型所用数据中超过真实数据”“到 2026 年 75% 的企业将使用生成式 AI 创建合成客户数据”，以及 2025 年提出的超合成数据（Hyper-Synthetic Data）方向<sup>[18][19][20][22]</sup>；两起代表性并购——NVIDIA 收购 Gretel（2025 年 3 月，金额超 3.2 亿美元）、SAS 收购 Hazy（2024 年 11 月）<sup>[23][24][25]</sup>；以及合成数据从“AI 模型训练数据”向“数据工程与软件测试数据”场景的持续外溢。这些信号的真实含义是：通用数据合成技术正在成为 AI 与数据分析基础设施的一部分，其供给侧的产业地位在快速上升。

落到银行业，上述热度还不能直接等同于落地条件，有三点要分开看。第一，银行可核实的投产案例很少。按第四章的口径，公开信息多为研究、试点和合作意向，国内暂无银行官方披露的规模化投产。第二，外部市场讲的“缺数据”与银行缺的不是同一种数据。互联网、自动驾驶缺的是数据量，银行缺的是合规可用、长尾覆盖的数据，把前者的紧迫性套到银行会估计过高。第三，从技术可用到监管认可还有距离，隐私计算此前也是技术先行多年后才逐步明确应用框架，合成数据目前同样规则未明（见第五章）。因此本报告的态度是：热度要

跟踪，立项要看银行自己的证据，先用小范围 POC 验证，再谈是否扩大。

#### （四）国内语境下的特殊性

在大陆监管环境下评估合成数据，有三个不宜直接套用国际说法的要点。其一，海外文献强调的“数据稀缺”在部分国际语境中指公开数据集的可得性，而国内大型银行的问题是数据“沉睡”与“不敢用”多于“没有”——即治理与合规约束下的可用性问题，这与“用合成数据造出本来不存在的数据”是两回事，须在价值论证中加以区分。其二，国内对“个人信息匿名化后能否自由使用”持审慎态度，监管部门并无合成数据“天然合规”的认定，《个人信息保护法》下的匿名化标准、金融领域对个人金融信息的特殊保护要求，使得“合成即安全”的宣传在国内尤其不能成立（第五章详析）<sup>[38][43]</sup>。其三，数据要素市场化改革（“数据二十条”）鼓励数据流通与价值释放<sup>[46]</sup>，合成数据作为可能的流通介质被寄予期望，但以数据交易所为代表的流通实践仍以可用不可见、隐私计算为主，合成数据尚未形成监管认可的流通范式。综合来看，国内银行引入合成数据应定位为“数据工程与隐私保护体系内的组件能力”，而非一项独立的业务主张。

#### （五）研究范围与证据口径声明

本报告面向我行科技条线决策，聚焦金融结构化（表格）数据的合成，兼顾文本与大模型相关方向，不覆盖自动驾驶

3D 仿真等非银行主流方向（仅作成熟度参照）。全报告对“某机构已采用/落地”的表述严格执行证据分级：A 生产应用、B 试点/概念验证、C 研究或实验、D 厂商自述且无独立证据；正文只把 A/B/C 作为案例证据，D 仅标注为厂商口径。市场数据一律多来源交叉并注明口径差异（第六章）。评级依据可追溯至正文证据链，方法与局限见附录一。

三、技术解析

（一）技术定义与核心概念

合成数据是指以真实数据为学习对象、由生成算法产出的新数据：它在统计分布和业务含义上与真实数据接近，但不直接对应任何一条真实记录。本报告主要讨论银行常用的结构化（表格）数据合成，文本类合成仅在涉及大模型语料时兼顾。

按对真实数据的依赖程度，业界通常三分：

表 2 合成数据三种形态

| 形态                         | 生成方式                 | 隐私与保真的权衡       | 典型用途             |
|----------------------------|----------------------|----------------|------------------|
| 完全合成 (Fully Synthetic)     | 全部字段由模型生成，模型从真实数据学习  | 隐私面最小，但保真度损失最大 | 公开数据集、跨机构共享      |
| 部分合成 (Partially Synthetic) | 仅敏感字段被替换生成，其余字段保留真实值 | 隐私与保真的折中       | 在保留分析价值的同时保护敏感字段 |

| 形态               | 生成方式             | 隐私与保真的权衡   | 典型用途           |
|------------------|------------------|------------|----------------|
| 混合合成<br>(Hybrid) | 真实样本与生成样本混合构成训练集 | 通过“混合比例”调节 | 小样本/长尾增强、测试集扩展 |

与本报告直接相关的核心概念还包括：条件生成（在指定客群、风险等级等条件下生成）、成员推断攻击（判断某条记录是否在训练集中）、差分隐私（对个体贡献施加可度量噪声的框架）、保真度—效用—隐私三维评价等。术语释义见附录二。

（二）技术原理与关键机制

对管理层而言，不必陷入公式，但需理解四个关键机制——它们分别决定了合成数据“凭什么可信、能不能按需用、好不好评估、安不安全”。

**机制一，分布学习与再采样：**合成数据的本质是“先学分布、再从分布采样”。生成模型在真实数据上学习字段间的联合分布与关联结构，再从中抽取“新的”样本。学得好不好，决定合成数据统计上像不像真实数据；这一机制决定了合成数据的天花板——它无法稳定地创造出训练数据中不存在的模式（这是理解“数据偏差放大”风险的入口）。

**机制二，条件化与业务约束：**通过条件生成控制输出的客群、产品、风险等级与取值范围，并可叠加字段间的业务规则约束（如利率与期限的单调关系、交易对手必须存在）。条件化是合成数据区别于“随机造数”、能够服务于定向建模与边界测试的关键。

**机制三，质量评估闭环：**合成数据不能“生而不评”。工程上须建立“统计保真度（分布与关联一致程度）—下游效用（在真实测试集上的任务表现）—隐私风险（成员推断/重识别攻击下的泄露水平）”三维评估，并以真实测试集作为最终裁判。评估闭环是否建立，是判断银行是否具备合成数据工程能力的分水岭。

**机制四，隐私保障的“显式化”：**生成模型可能记忆训练样本。若不在生成流程中显式引入差分隐私等机制并做攻击性验证，“合成数据更安全”就是未经证实的假设（详见本章第（六）节与第五章）。机制四回答的是“合成数据的隐私声明是否经得起审计”。

四者在工程上构成“数据建模—条件生成—质量评估—隐私审计”的循环，通常以合成引擎组件嵌入数据中台，与脱敏、特征平台、模型训练和模型风险管理协同（示意图：真实数据→预处理与特征→生成模型训练→条件采样→质量与隐私评估→合格样本进入建模/测试/共享；模型效果反馈回流至生成参数）。该定位决定了银行应以组件化而非独立平台方式引入。

补充说明质量评估的具体口径，以便工程落地。三维评价可操作化为：保真度（Fidelity）用分布距离（如 Wasserstein 距离）与字段关联误差度量；效用（Utility）以下游任务在真实测试集上的表现度量（分类用 AUC/KS/召回、回归用误差指标）；隐私（Privacy）以成员推断攻击成功率相对随机基线的偏移、重识别率与差分隐私预算  $\epsilon$  度量。三者构成工程意义上的“不可能三角”——提升任意两者通常以第三者为代价，因此银行的质量评估规范应显式记录每次生成的“保真度—效用—隐私”折中位置与生成参数，作为可审计、可复现的元数据。




图 1 合成数据质量三维评价（保真度—效用—隐私）关系示意（自绘）

（三）技术演进脉络：每一代解决了上一代的什么问题

表 3 合成数据技术演进时间线（全球技术线与金融应用线双轨）

| 时间             | 全球技术演进<br>(代表成果)                                         | 解决了上一代的什么问题                                          | 金融/银行侧节点                       |
|----------------|----------------------------------------------------------|------------------------------------------------------|--------------------------------|
| 1987—<br>2000s | 多重插补<br>(Rubin) 与统计合成思想；官方统计机构探索合成微观数据 <sup>[8][9]</sup> | 以统计模型系统化“生成缺失与敏感值”，解决数据可得性与保密性的矛盾，奠定“生成数据可用于分析”的思想基础 | 统计分析、抽样调查阶段                    |
| 2002           | SMOTE 少数类过采样 <sup>[7]</sup>                              | 以插值方式缓解分类中的类不平衡，先于深度学习成为表格数据增强的经典工具                  | 被后续信用卡欺诈研究广泛采用 <sup>[17]</sup> |
| 2006—          | 差分隐私框架提                                                  | 为“可证明                                                | 监管统计领域早期参照                     |

| 时间            | 全球技术演进<br>(代表成果)                                                                     | 解决了上一<br>代的什么问<br>题                                                  | 金融/银行侧节点    |
|---------------|--------------------------------------------------------------------------------------|----------------------------------------------------------------------|-------------|
| 2013          | 出 (Dwork) <sup>[11]</sup> ;<br>美国人口普查局<br>发布 SIPP 合成<br>数据产品 (SSB)<br><sup>[9]</sup> | 的隐私”提<br>供数学工<br>具; 以官方<br>实践验证统<br>计合成数据<br>的可信发布<br>路径             |             |
| 2013—<br>2014 | VAE (Kingma &<br>Welling) <sup>[2]</sup> 、GAN<br>(Goodfellow<br>等) <sup>[1]</sup>    | 深度生成模<br>型让“高<br>维、连续数<br>据”的自动<br>生成成为可<br>能; GAN 开<br>创对抗式分<br>布学习 | 深度合成技术的学术起点 |
| 2016—<br>2017 | SDV 开源合成库<br><sup>[10]</sup> ; PrivBayes<br>差分隐私表格合<br>成 <sup>[16]</sup>             | 把生成模型<br>工程化为表<br>格数据工<br>具; 把差分<br>隐私引入表<br>格合成, 回<br>应隐私质疑         | 数据科学社区工具化阶段 |

| 时间            | 全球技术演进<br>(代表成果)                                                                      | 解决了上一<br>代的什么问<br>题                              | 金融/银行侧节点                                                                                                  |
|---------------|---------------------------------------------------------------------------------------|--------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| 2019          | CTGAN (Xu 等) <sup>[4]</sup>                                                           | 针对表格数据的离散字段与类不平衡，提出条件生成与分位数归一化，使 GAN 在表格数据上首次实用化 | 此后大量风控/欺诈合成研究以 CTGAN 为基线                                                                                  |
| 2020          | DDPM 扩散模型 (Ho 等) <sup>[3]</sup>                                                       | 生成质量与训练稳定性显著优于 GAN，成为图像等高维生成的主流                  | 同期银行业出现合成数据试点 (Nationwide×Hazy 等，B 级证据) <sup>[32]</sup>                                                   |
| 2022—<br>2023 | TabDDPM 表格扩散模型 <sup>[5]</sup> ；GReaT 等大模型表格生成 <sup>[6]</sup> ；Gartner 将合成数据列入数据与分析顶级趋 | TabDDPM 在多项表格基准上超过 GAN 类方法；LLM 把“文本语             | 银行侧：JPM AI Research 发布合成数据集（研究级） <sup>[34]</sup> ；Gartner 预测 2026 年 75% 企业使用生成式 AI 合成客户数据 <sup>[20]</sup> |

| 时间            | 全球技术演进<br>(代表成果)                                                                                                                          | 解决了上一<br>代的什么问<br>题                                  | 金融/银行侧节点                                                                                                                 |
|---------------|-------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------|
|               | 势 <sup>[18]</sup>                                                                                                                         | 义”引入表格与语料合成，解决表格字段稀疏与文本特征问题                          |                                                                                                                          |
| 2024—<br>2026 | 超合成数据<br>(Gartner, 2025) <sup>[22]</sup> ；SAS<br>收购 Hazy<br>(2024) <sup>[25]</sup> ；<br>NVIDIA 收购<br>Gretel (2025)<br><sup>[23][24]</sup> | 从“补数据”走向“造世界”（仿真、智能体与多模态环境数据）；产业并购标志能力并入数据与 AI 基础设施栈 | 银行侧：Riyad<br>Bank×zypl.ai 签署合作<br>备忘录（B 级）[36]；<br>UnionBank 参与合成数据<br>共享生态研究（C 级）<br><sup>[35]</sup> ；国内未见银行官方生<br>产级披露 |

从时间线可以看出三层规律。第一层，技术主线是从“统计再造”走向“深度生成”再到“语义生成”：每一代都在提高对复杂分布（高维、非结构化、强关联）的拟合能力，但代价是模型更复杂、可解释性更弱、对训练数据的记忆风险更高

——隐私问题因此随代际加重而非减轻。第二层，金融业的采纳明显滞后于通用技术成熟度：学术方法出现到银行试点通常滞后 5 年以上，且银行业公开证据大多停留在试点与研究层。第三层，2024—2025 年两起并购把合成数据能力并入 NVIDIA 与 SAS 的 AI/数据平台，意味着对银行而言，“是否采用合成数据”正在变成“如何在自己的数据平台上使用合成数据能力”，自建底层生成模型的需求将下降。

#### （四）四类主流技术路线：原理、工程意义与金融适用性

本小节对当前四类主流生成路线逐条剖析，统一按“基本原理—代表方法与表格适应性—优势—局限—质量与隐私表现—金融适用场景—成熟度”展开。写作原则是不堆公式、突出工程判断。

##### 1. 生成对抗网络（GAN）

原理与机制。GAN 由生成器与判别器两个网络对抗训练：生成器把随机噪声映射为“看起来像真实数据”的样本，判别器判断输入是真实还是生成；两者博弈使生成器逐步逼近真实分布[1]。工程意义在于：GAN 不显式假设数据分布形态，能端到端学习高维、复杂、难以手工建模的字段关系；训练完成后生成速度快、采样成本低。

对表格数据的适应性。原始 GAN 面向连续图像数据，直接用于金融表格数据（混合连续字段与大量离散枚举字段、取

值分布极不均衡）会遭遇训练不稳定与模式崩溃。CTGAN 通过“类别条件生成+连续字段分位数归一化+小批量加权”三项改造，首次让 GAN 在表格数据上可实用[4]，其后的 CopulaGAN、CTAB-GAN 等进一步适配多字段约束，SDV 将这类方法工程化开源[10]。

优势与局限。优势是生成速度快、对表格数据的条件化支持好（按客群、风险等级定向采样）、与下游建模框架衔接自然。局限集中在三处：一是训练不稳定，模式崩溃导致生成多样性下降且难以察觉；二是判别器可能走捷径，生成分布与实际分布存在系统性偏离；三是可解释性弱、调参依赖经验。学术基准普遍显示，在多样性与分布保真上，GAN 类方法已不再领先于扩散模型类方法[5]。

质量、隐私与金融适用。质量上，GAN 在类不平衡增强（欺诈少数类）上被长期研究，Fiore 等的经典实验表明以 GAN 合成少数类扩充训练集可提升欺诈检测灵敏度[17]——这是“合成数据用于风控”方向上引用最多的学术证据（属 C 级证据，非银行生产披露）。隐私上，GAN 可能记忆训练样本，成员推断攻击对 GAN 的威胁已被反复证实[12][14]。成熟度判断：GAN 类方法研究最充分、工具最成熟，属于“可用但需防训练失控与隐私记忆”的中坚路线；因深度学习框架成熟、社区工具丰富（SDV、CTGAN 等均开源），工程门槛最低，是 PoC 的首选基线。

## 2. 变分自编码器（VAE）及其表格变体

原理与机制。VAE 以“编码器—解码器”结构把数据压缩为低维潜在变量，再从潜在分布采样解码还原数据，通过变分下界训练使生成分布逼近真实分布[2]。工程意义是训练稳定、理论清晰，潜在空间可解释、便于插值与条件控制。

对表格数据的适应性。表格变体 TVAE（连同 CTGAN 同批提出）把连续与离散字段编码到潜在空间统一建模，适用于字段结构复杂但维度不高的表。整体上 VAE 生成样本偏“平滑”，容易丢失极端值，这一特性与金融数据重尾部、重极端事件的特性不匹配。

优势与局限。优势是训练稳定、生成速度快、潜在空间便于做平滑插值（如模拟介于两个客群之间的样本）；局限是生成质量上限偏低（易模糊、多样性不足），难以精确再现金融数据中的稀疏事件与长尾分布。质量与隐私表现介于 GAN 与扩散方法之间；隐私方面同样存在记忆风险，需以差分隐私约束潜在空间。

金融适用与成熟度。VAE 更适合作为“数据探查与潜在特征学习”组件，或在强条件约束、低维表格场景作为轻量方案；金融场景中很少单独作为高保真合成主力。成熟度较高但应用价值边际有限，通常作为对比基线与补充方法使用。

### 3. 扩散模型 (Diffusion Model)

原理与机制。扩散模型通过两步学习：前向过程逐步向数据加噪直至纯噪声，反向过程学习逐级去噪、从噪声中还原数据；生成时从纯噪声出发按学习到的去噪步骤采样[3]。其工程意义在于训练目标稳定、不易模式崩溃，生成质量在图像等领域显著超过 GAN，被主流判断为当前高保真生成的第一梯队方法。

对表格数据的适应性。表格数据与图像在扩散建模上存在本质差异：图像可按像素网格加噪，表格没有天然空间结构且字段类型混杂。TabDDPM 等将加噪/去噪改造到字段级，并引入分类字段的掩码式噪声，在多份公开表格基准上取得优于 CTGAN 的质量与多样性成绩[5]。2024—2025 年进一步出现面向多表关联与时间序列的扩散合成研究，使该方法向银行数据常见的“多表+时间维”结构靠近。

优势与局限。优势是生成质量高、多样性好、训练稳定；局限是采样速度慢（逐级去噪，推理成本高于 GAN/VAE）、工程调优与算力成本较高，且生成的“精确性”与“创造性”之间更难控制——对必须严格满足字段业务约束的银行数据，往往需要在采样端叠加规则校验。质量表现当前最优一档；隐私方面，研究同样提示扩散模型存在训练数据记忆问题，须配合差分隐私训练或生成后审计[14]。

金融适用与成熟度。适合对保真度要求高的场景：小样本风控建模的数据增强、高维特征表合成、多表关联的测试数据生成。成熟度处于“工程化早期、有限生产试点”：方法成熟、开源实现可用（如 TabDDPM 复现与商业平台接入），但银行生产案例不足，属 18—36 个月阶段重点跟踪路线。

#### 4. 大语言模型驱动的合成（LLM-driven）

原理与机制。LLM 以自回归方式按词元预测文本；将其用于合成数据，是把表格的每一行“翻译”为自然语言描述，让模型学会“生成像真实记录一样的句子”，再解析回结构化字段（代表性工作如 GReaT）[6]。大模型路线同时覆盖两类银行需求：一是文本类数据的合成（客服对话、合同与尽调文本、舆情语料的匿名化与扩充）；二是“合成客户数据”说法——以生成式 AI 创造模拟客户与场景（Gartner 2026 年 75% 口径所指方向）[20]。

产业与研究侧佐证。头部 AI 机构已将“合成数据+自动校验+模型微调”规模化用于大模型研发：DeepSeek 团队在 DeepSeek-Prover 中，以约 800 万条由高中与本科数学竞赛题自动翻译、过滤并形式化证明的 Lean 4 语句构造合成训练集，微调 DeepSeekMath-7B 后，在 miniF2F 形式定理证明基准上整句生成通过率约 50%，超过此前最优水平（41.0%）[51]。另一类实践则走向“任务导向”升级：Intel Labs 以“分析弱模型推理缺陷→定向生成合成样本→自动质检过滤”

的方式，为多模态模型构造了 55.3 万条指令数据，说明合成数据生成正从“求量”转向“对准已知缺陷、可自动校验”[54]。DeepSeek-Prover 案例对银行的启示有三：其一，合成数据已被证明可在强逻辑、可自动校验的任务上规模化供给高质量训练语料，印证“LLM 驱动合成”不是实验室概念；其二，其关键成功要素是形式化校验环节——每条合成语料的正确性可被编译器自动判定，而银行场景的合成文本/表格缺乏此类自动真值判定，这提醒银行对“不可校验”的合成语料保持更高审慎（呼应第五章幻觉风险）；其三，该类实践属大模型研发域、与银行直接场景相距较远，本报告仅作技术趋势佐证，不改变任何评级。

优势与局限。优势是能利用 LLM 的世界知识与语义理解生成上下文一致、语义自然的样本，天然处理文本字段，并可通过提示词注入业务约束（“生成一位月收入 2 万元、偏好稳健理财的 35 岁客户”）。局限明显：一是成本高、速度慢，大规模行级生成不经济；二是“幻觉”风险——生成的字段组合可能在统计上罕见甚至业务上不可能，须强约束校验；三是可解释性与审计难度大；四是若以真实个人信息微调或作为上下文输入，将直接触及金融领域生成式 AI 训练禁令的合规红线[43]。

质量、隐私与金融适用。质量上，LLM 方法在表格语义一致性上有优势，但在精确复现数值分布上并不必然优于扩散方

法，仍处快速演进期。隐私上，LLM 对训练语料的记忆问题更为突出，“提示词+输出”路径的隐私边界尚不清晰。金融适用场景应限定在文本语料合成、评测集构造与可公开数据的受限用途；凡涉及个人金融信息的训练输入须先做严格去标识化评估。成熟度：处于早期采用阶段（2023 年以来快速演进），PoC 可评估、生产需谨慎。

5. 相邻路线的必要交代

除上述深度生成路线外，统计与差分隐私路线（如 PrivBayes 网络贝叶斯合成、机制化边际合成）在“可证明隐私”上有不可替代的价值，但保真度与规模受限[16]。图像/3D 仿真与多模态合成（NVIDIA Omniverse/Cosmos 生态）在自动驾驶与具身智能领域已规模化，属合成数据最成熟子域，但并非银行主场景，仅作成熟度参照，不展开。以上路线的横向比较见下表。

表 4 四类核心技术路线横向比较

| 比较维度       | GAN 类（如 CTGAN） | VAE 类（如 TVAE） | 扩散模型类（如 TabDDPM） | LLM 驱动（如 GReaT） |
|------------|----------------|---------------|------------------|-----------------|
| 生成质量（分布保真） | 中—良            | 中             | 优                | 良（语义优、数值分布中—良）  |
| 训练稳定       | 差（易模式崩         | 好             | 好                | 好（依赖预训          |

| 比较维度          | GAN 类（如 CTGAN） | VAE 类（如 TVAE） | 扩散模型类（如 TabDDPM） | LLM 驱动（如 GReaT） |
|---------------|----------------|---------------|------------------|-----------------|
| 性             | 溃）             |               |                  | 练底座）            |
| 生成速度          | 快              | 快             | 慢（逐级去噪）          | 慢（自回归）          |
| 数据多样性         | 中（模式崩溃时差）      | 中             | 优                | 优（受提示约束影响）      |
| 可控性/条件生成      | 良              | 中             | 良                | 优（自然语言条件）       |
| 可解释性          | 弱              | 中（潜在空间可探）     | 弱                | 中—弱             |
| 表格数据适应性       | 良（改造后）         | 中             | 良—优              | 中—良             |
| 文本数据适应性       | 差              | 差             | 中                | 优               |
| 隐私风险（记忆/成员推断） | 高（未加 DP 时）     | 中—高           | 高（未加 DP 时）       | 高（语料记忆）         |
| 算力与成本要求       | 低—中            | 低             | 高                | 高               |
| 银行金融场景成熟      | 较高（研究多、工具全，    | 低（多为补充组       | 中（工程化早期）         | 低—中（文本域试点，受合    |

| 比较维度 | GAN 类（如 CTGAN） | VAE 类（如 TVAE） | 扩散模型类（如 TabDDPM） | LLM 驱动（如 GReaT）   |
|------|----------------|---------------|------------------|-------------------|
| 度    | 可作 PoC 基线）     | 件）            |                  | 规约束）              |
| 典型定位 | 欺诈/长尾增强、测试数据生成 | 潜在特征学习、轻量合成   | 高保真表格/多表合成（中期路线） | 文本合成、语义一致样本、大模型语料 |

表 4 的判断要点：不存在“全维度最优”的单一路线，银行应把四类路线视为可组合的工具箱，而不是二选一的平台选型；以 CTGAN 为 PoC 基线、以扩散类为中期高保真升级方向、以大模型类在文本受限场景单独评估，是更合理的技术策略。

（五）与真实数据、脱敏、匿名化、隐私计算及数据增强的关系

合成数据进入银行数据体系时，最容易被问的问题不是“它能不能用”，而是“它和脱敏、隐私计算到底是什么关系，是不是重复建设”。本节给出明确边界。

四类技术解决的问题本质不同：合成数据解决“如何产生新的、可用的数据”；脱敏/匿名化解决“如何降低既有真实数据的识别风险”；联邦学习解决“数据不能集中时如何协同训练”；多方安全计算等解决“在不直接暴露数据的情况下如

何共同计算”。它们分别作用于数据生命周期的不同环节——生成、改造、训练、计算——因此是互补关系而非替代关系。合成数据与真实数据的关系则是“互补且依赖”：合成数据的分布来源仍是真实数据，真实数据提供真实性与权威性，合成数据提供充足性、多样性与可控性；一个可行的银行数据供给体系是“真实数据+合成数据”的混合体系，而非以合成数据替代真实数据。

表 5 合成数据与既有技术的关系对照

| 维度                  | 真实数据      | 脱敏<br>(掩码/<br>泛化/置<br>换) | 匿名化<br>(含 k-<br>匿名族)   | 联邦学<br>习/多方<br>安全计<br>算 | 数据增强<br>(SMOTE<br>等) | 合成数据<br>(本文主<br>线) |
|---------------------|-----------|--------------------------|------------------------|-------------------------|----------------------|--------------------|
| 回答<br>的问题           | 发生了<br>什么 | 如何降<br>低原数<br>据识别<br>风险  | 如何使<br>个体不<br>可再识<br>别 | 数据不<br>集中时<br>如何协<br>同  | 如何扩展<br>现有样本         | 如何生成<br>新的可用<br>数据 |
| 数据<br>来源            | 真实采<br>集  | 真实数<br>据改造               | 真实数<br>据改造             | 真实数<br>据不共<br>享         | 真实样本<br>变换           | 学习分布<br>后生成        |
| 是否<br>新增<br>样本<br>量 | 否         | 否                        | 否                      | 否（仅<br>模型参<br>数流<br>动）  | 是（插值/<br>扰动）         | 是（任意<br>规模）        |

| 维度             | 真实数据             | 脱敏<br>(掩码/<br>泛化/置<br>换) | 匿名化<br>(含 k-<br>匿名族)     | 联邦学<br>习/多方<br>安全计<br>算 | 数据增强<br>(SMOTE<br>等) | 合成数据<br>(本文主<br>线)            |
|----------------|------------------|--------------------------|--------------------------|-------------------------|----------------------|-------------------------------|
| 统计<br>保真       | 高                | 中(破<br>坏关<br>联)          | 中—低<br>(泛化<br>损失)        | 高(不<br>改变数<br>据)        | 中(局部<br>插值)          | 中—高<br>(取决于<br>方法与约<br>束)     |
| 隐私<br>强度       | 无                | 弱—中<br>(重识<br>别残<br>存)   | 中(受<br>背景知<br>识攻击<br>影响) | 中—高<br>(原始<br>不出<br>域)  | 无(基于<br>真实样<br>本)    | 无内生保<br>障, 须叠<br>加差分隐<br>私与审计 |
| 金融<br>典型<br>用途 | 生产、<br>建模、<br>报送 | 测试、<br>展示                | 统计发<br>布                 | 跨机构<br>联合建<br>模         | 小样本建<br>模            | 测试数<br>据、样本<br>扩充、受<br>限共享    |

关系要点可归纳为三条。其一，合成数据不是脱敏的“升级版”：脱敏保留真实记录的骨架、抹去可识别信息，合成数据则重建整个分布；二者在保真形态与风险特征上都不同，银行在多数场景应先问“脱敏够不够”，再考虑合成。其二，合成数据与隐私计算可组合：先以差分隐私机制生成合成数据、再以隐私计算做跨机构使用，构成纵深防御，而非二选一。其三，从银行科技体系建设角度看，合成数据最合理的落点是数

据工程/数据中台内的一个“数据供给组件”，与脱敏、访问控制、隐私计算并列于数据服务与安全能力集——这正是本报告第七章定位判断与第九章组件化路线的前提。




图 2 合成数据与真实数据、脱敏/匿名化及隐私计算的关系示意（自绘）

（六）一个必须澄清的命题：合成数据并不天然隐私安全

行业宣传常见“合成数据不含真实个人信息，因此无隐私风险”，这一命题经不起实证检验，是本报告必须先行澄清的观点。

**第一**，生成模型会记忆训练数据。深度生成模型容量大，可能把训练集中高频或异常样本“记住”并在生成时复现；成员推断攻击可在“目标记录是否参与训练”上取得显著高于随机猜测的成功率[12]；模型反演攻击可从模型输出重构训练样本的敏感属性[13]。这意味着“模型生成的数据”与“真实个体信息”之间不存在天然防火墙。

**第二，“匿名化”结论取决于攻击者背景知识。**合成数据即便不逐字复现真实记录，仍可能保留个体级模式；攻击者若掌握部分真实信息（如年龄、地域），可将合成记录与真实个体链接，形成重识别与属性推断。Stadler 等对主流合成工具的系统性测评结论是：与差分隐私相比，多数商用合成方法未达到“可证明的匿名化”，其隐私保护效果被明显高估；而一旦施加严格的差分隐私约束，合成数据的效用又显著下降——即存在“隐私—效用”权衡[14]。该结论应作为本报告风险判断的核心证据。

**第三，形式化隐私必须显式构建。**当前唯一被广泛接受的强隐私定义是差分隐私：它通过校准噪声限制“任一单条记录”对输出的影响，可对隐私损失给出可度量上界[11]。把差分隐私嵌入生成训练（DP-SGD）或嵌入合成模型（如 PrivBayes、机制化边际合成[16]），合成数据才具备可审计的隐私声明。但差分隐私并非免费：隐私预算越小、噪声越大、合成效用越低，银行须在具体场景中显式设定隐私预算并接受对应的效用损失，而不是默认“又安全又可用”。

2025 年发表于 ICLR 的一项系统性检验，把“用合成数据训练能保护隐私”的说法拆开验证，覆盖四类常见做法，结论是一致的：在没有差分隐私这类形式化保证的情况下，换用合成数据训练并不能自动保护原始数据，缺少严格攻击性评估反而容易带来“虚假的安全感”[52]。四类做法的区别在于：核

心集选择是从原始数据中直接挑选子集训练，模型见过真实记录，泄露风险最高；数据集蒸馏是把大数据集压缩成少量合成样本，若用真实数据做初始化，成员推断攻击成功率明显偏高，改用噪声或外部数据初始化能降低风险，但模型效果也随之下降低；无数据知识蒸馏是先的真实数据上训练教师模型、再用合成数据训练学生模型，即使合成图像与原图看起来完全不像，学生仍能继承教师对个别样本的记忆；扩散模型合成是先在有数据上微调扩散模型再生成，其中保留原标签的“图生图”仍会泄露，纯文本提示生成相对好一些，但效率远低于差分隐私基线。该研究把四类做法与差分隐私随机梯度下降（DP-SGD）同口径对比，在相近效果下 DP-SGD 的隐私—效用—效率权衡仍是最优的。这支持本报告的验收要求：任何“隐私保护型合成”方案都要有形式化机制并通过独立攻击性审计。

**结论：**银行评价任何“隐私保护型合成数据”方案时，必须追问三件事——是否在生成流程中引入了形式化隐私机制；是否经过成员推断/重识别攻击的独立审计；隐私预算与效用损失是否在业务可接受范围。凡三者不能闭环的方案，应按脱敏数据的同等安全级别管理，而不是按“已匿名化数据”简化管理（第五章监管映射详述）。

## （七）技术成熟度评级

综合 Gartner 跟踪定位、TRL 就绪度、产品与生产案例、标准化程度四方面证据，本报告对合成数据的技术成熟度评级

为 3 分。评级口径说明：本报告以“银行可用性”为目标域——重点考察金融表格数据合成这一银行主战场，而非图像/3D 仿真等非金融子域；若仅按计算机视觉仿真等最成熟子域评估，其就绪度可到 TRL 7—8 的生产级，但银行主场景的证据不支持该结论。

表 6 技术成熟度评级证据链（评级：3 分）

| 证据维度                  | 关键事实                                                                                                            | 信源与核实状态                       |
|-----------------------|-----------------------------------------------------------------------------------------------------------------|-------------------------------|
| Gartner/Hype Cycle 定位 | 2022 年列入数据与分析顶级趋势 [18]；2024—2025 年仍以“新兴技术/颠覆者”框架跟踪，2025 年提出超合成数据、判断 5—10 年内重塑 AI 服务[22][48]；未见其处于主流生产成熟区的官方曲线定位 | Gartner 会员文档与公开条目（部分经第三方转引核实） |
| TRL 就绪度（分域）           | 图像/3D 仿真与软件测试数据子域 TRL 7—8（生产可用）；金融表格数据合成 TRL 5—6（工具成熟、银行生产案例稀少）；LLM 驱动合成 TRL 4—5                                | 本章时间线与第四章案例证据                 |
| 产品与生产案例               | 通用工具成熟（SDV 等开源、Gretel/Mostly/Tonic 等商用，NVIDIA、SAS 并购整合）[23][25]；银行侧多为试点与研究，无公开的生产级量化案例群                         | 第四章案例分级                       |
| 标准化程度                 | 缺乏生成质量与隐私评估的统一标准；                                                                                               | 综合检索结                         |

| 证据维度  | 关键事实                                          | 信源与核实状态 |
|-------|-----------------------------------------------|---------|
|       | 质量评测多依赖社区基准与厂商自评；Gartner、ISO 等尚无针对合成数据质量的通用标准 | 果       |
| 目标域判断 | 银行表格数据合成处于“早期采用、标准初定、有限生产试点”阶段                | 本报告评级结论 |

评级说明：技术成熟度 3 分对应撰写规范中“泡沫破裂低谷期 / TRL 5—6 / 有限生产试点”档位。需要说明的是，两个信号指向不同档位：通用生成算法与工具链成熟度接近 4 分档（复苏爬坡、多个行业有生产案例），但“银行域标准化与生产证据”仅对应 3 分档；按审慎原则并考虑本报告服务银行决策的目的，取 3 分。若未来 12—18 个月出现 2 家以上可比银行的公开生产级案例并形成质量评估行标，应重评至 4 分并同步触发处置档位复评（第八章）。

## 四、应用场景与价值实证

### （一）业务场景识别与总体判断

本章回答一个决策问题：合成数据在我行哪些场景能创造可验证的价值、价值量级多大、证据强度如何。场景识别采用“从待办任务出发”的方法（JTBD, Jobs-to-be-Done）：不先问“技术能做什么”，而先问银行在哪些环节长期存在“数

据供给不达标”的具体任务。按此方法筛选出四个主场景与一个延伸场景，并按“业务价值—技术就绪—实施难度”三维定位如下。

表 7 银行合成数据应用场景矩阵

| 场景            | 业务任务与痛点                       | 价值清晰度           | 技术就绪度 | 实施难度      | 优先级            |
|---------------|-------------------------------|-----------------|-------|-----------|----------------|
| 1 风控模型训练数据增强  | 违约/欺诈/流失等长尾样本不足、新客群无历史        | 中（学术证据支持、行内待验证） | 中—高   | 中         | 高（POC之二）       |
| 2 反欺诈与异常检测    | 欺诈样本极端稀少、模式演化快、误报控制难          | 中               | 中—高   | 中         | 高（可与场景 1 合并评估） |
| 3 测试数据生成与系统验证 | 开发/回归/压力测试数据依赖人工造数、合规限制真实数据下移 | 高（行业验证充分）       | 高     | 低         | 最高（POC之首）      |
| 4 数据共享与隐私保护   | 部门/子公司/外部协作中真实数据流转受限          | 中低（方向合理、证据有限）   | 中     | 高（治理牵涉面广） | 中（跟踪评估）        |

| 场景                          | 业务任务与痛点                      | 价值清晰<br>度 | 技术<br>就<br>绪<br>度 | 实施难<br>度               | 优先级         |
|-----------------------------|------------------------------|-----------|-------------------|------------------------|-------------|
| 5（延伸）<br>大模型语<br>料与文本<br>合成 | 垂类模型训练/评<br>测语料不足、文<br>本隐私合规 | 中         | 低<br>—<br>中       | 中—高<br>（合规<br>约束<br>强） | 低（观察<br>评估） |

场景 3 的行业证据最充分、最易量化，是 POC 首选；场景 1/2 学术证据指向正向、但须以真实测试集做严谨对比，不宜照搬“提升 AUC”式的厂商话术；场景 4/5 现阶段以跟踪与受限评估为主。下述各场景中的量化均为示意口径，非我行实测、非收益承诺。

## （二）场景一：风控模型训练数据增强

痛点再聚焦。银行风控模型（信用评分、额度管理、早期预警）面临的不是“总量缺数据”，而是结构性缺口：违约样本占比低、新客群与新产品无历史表现、极端情景无样本。由此导致模型对长尾高风险客群的区分能力不足，且新策略上线前难以充分回测。

合成数据的介入方式有两种。一是少数类扩充：以 SMOTE 类插值或生成模型合成违约/高风险样本，改善训练集的类平

衡[7]；二是条件化分布补充：按目标客群特征生成近似样本，缓解“新客群无历史”问题。两种方式在学术上的定位不同：前者有较一致的正面证据，后者（生成无历史数据客群）本质上依赖外推，须谨慎——生成模型学不到训练分布之外的稳定规律，条件化生成“低资产、新开户、学生客群”的样本只能近似其统计形态，无法凭空获得真实的违约关系（见第五章偏差放大风险）。

证据与反证。Fiore 等以 GAN 合成信用卡欺诈少数类的实验表明，在增强集上训练的分类器灵敏度（对欺诈的识别率）优于仅在原始数据上训练的模型[17]——这是支持“合成增强可提升长尾识别”的主要学术证据，但其数据集规模有限、且属学术级验证。反方向的证据同样存在：当原始样本量充足时，加入合成数据未必带来 AUC/KS 的提升，甚至可能因引入分布偏差而劣化；多项合成数据效用研究的普遍结论是“效用高度依赖数据形态、生成方法与任务”，不存在放之四海皆准的收益。因此，本报告明确反对“合成数据可以显著提升风控模型性能”这类未经验证的表述，而将其表述为：在少数类/长尾稀缺且基线模型明显欠拟合的场景下，合成增强具有提升召回等指标的潜力，须经行内真实测试集验证后方可确认。

验收标准设计。风控场景 POC 的验收必须回答“是否真正改善了指标”，建议统一按以下口径执行：以同一真实测试集（不掺入任何合成样本）为裁判，比较“真实训练基线、

SMOTE 基线、合成增强、真实+合成混合”四组方案的 AUC、KS、Recall@KS 阈值与稳定性指标；仅在“合成方案在多数指标上不劣于基线、且长尾分段指标显著改善”时才判定通过。任何只报生成数据内部指标（如距离度量）而不报真实测试集下游指标的方案，一律不作为价值证据。

### （三）场景二：反欺诈与异常检测

痛点再聚焦。欺诈检测与场景一的差异在于两点：欺诈样本占比往往低于千分之一（类不平衡更极端）；欺诈模式随攻防快速演化，模型滞后于新欺诈手法。传统解决思路（欠采样、SMOTE、代价敏感学习）在极端不平衡下有各自瓶颈。

合成数据的两个潜在价值点。其一，少数类增强用于模型训练：学术证据集中在信用卡交易欺诈上，除前述 Fiore 等工作外，2024—2025 年仍有将 GAN 与 Transformer 混合用于欺诈样本生成的研究，提示该方向仍在活跃演化。其二，欺诈“模式库”与压力测试：以条件生成构造“已知欺诈模式的变体”，用于反欺诈模型的回归测试与查全率压力测试——这比“生成新欺诈”更现实，因为模型无法凭空产生训练分布之外的攻击模式。

需要提示的三点风险。其一，欺诈数据的高维稀疏性与极强的时效性使合成难度高于一般信贷数据——历史上欺诈特征会迅速过时，合成“历史欺诈”对“新欺诈”的增益有限；其二，误报控制是反欺诈的主目标之一，合成样本引入的分布噪

声可能抬高误报率，须以“误报率不劣化”作为与召回同等重要的验收约束；其三，将合成增强用于反洗钱模型须额外注意监管对模型可解释性的要求，黑箱生成样本的合规说明成本较高。综上，反欺诈场景建议与风控场景合并开展同一 POC 的对照评估，而不单独立项。

#### （四）场景三：测试数据生成与系统验证

痛点再聚焦。银行开发测试环境需要大量“像生产一样”的数据，但真实生产数据受个人信息保护约束不能直接下移，人工造数与脱敏数据是当前两大现实方案。其痛点具体而可度量：人工造数依赖业务专家手工构造，边界条件与极端交易覆盖靠运气；脱敏数据字段关联被破坏，回归测试中“脱敏后字段组合导致规则分支未被覆盖”的问题频发；测试数据准备在大型系统版本中往往以周计。

行业证据显示这是合成数据最成熟的落地域。测试数据管理（TDM）本身是银行信息化长期工程能力（代表性商业工具如 IBM InfoSphere Optim 等），其核心方法论即“从生产数据提取子集+规则化变换+按需生成”，与本报告的“以生成方式供应测试数据”理念一致，银行业使用成熟[49]。以生成模型合成测试数据的增量价值在于：按统计分布重建字段关联，比“掩码置换式脱敏”更接近生产分布；可条件化生成边界样本（超柜面限额、极端金额、罕见账户状态组合）；生成规模不受真实样本限制。Nationwide 案例提供了量化参照：其以

合成数据支持外部创新伙伴的数据评估，据厂商披露将相关流程从 6 个月缩短至 3 天[32][33]（详见本章第（七）节案例）。

但需澄清一个常见误解：合成数据并不天然比脱敏数据更高效。在两类情形下脱敏仍占优：一是测试仅需“字段格式正确”而非“统计分布相似”时（如纯页面展示测试），合成属于过度投入；二是当真实数据的字段关联规则极其复杂、生成模型难以精确还原时，基于真实数据的规则化脱敏（保留关联）反而保真更高。因此场景三建议“分类分级使用”：先建立测试数据需求分级（格式型 / 结构型 / 分布型），分布型需求才引入合成生成；同时以可度量的“数据准备工时、缺陷发现率、分支覆盖提升、合规审批周期”四指标评估增量价值，而不是默认替换。

#### （五）场景四：数据共享与隐私保护

痛点再聚焦。银行数据共享可分为四层：行内部门与条线间、集团母子公司间、与外部持牌机构/金融科技公司间、与科研与监管间。真实数据的流转瓶颈在授权与安全评估环节——一个人金融信息的跨主体提供须逐层评估授权基础，导致共享周期长、范围窄。

合成数据在此场景的定位是“介质”而非“制度”：它可以提供不指向真实个体的数据形态，但能否流转仍取决于授权链条与用途合法性。国内外证据的强度需分层说明。研究侧：

SynDEc 项目（2025）以设计科学研究方式与包括菲律宾 UnionBank 在内的两家银行构建“合成数据共享生态”，验证了金融场景下合成数据共享的可行性框架，属研究级证据（C 级）[35]。产业侧：Nationwide 与 Hazy 的案例证明“以合成数据向第三方提供评估数据集”在英欧 GDPR 语境下可行[32][33]。国内侧：需明确两点——其一，数据要素流通政策鼓励“可用不可见”，但合成数据尚未被监管认定为匿名化数据，其对外提供仍应适用个人信息对外提供的合规审查（第五章监管映射）；其二，公开渠道未检索到国内银行披露的、以合成数据开展跨机构数据流通的生产级案例，现有国内说法多为隐私计算厂商的方案宣传（D 级），本报告不采信为案例证据。

**结论：**场景四方向合理，但受制于监管认可度与内部治理成熟度，应定位为中期跟踪场景——在场景一、三形成质量评估与隐私审计能力后再行评估，不宜作为首个 POC。

## （六）延伸场景：大模型语料、评测与“合成客户”说法

银行垂类大模型建设对高质量文本语料与评测集有现实需求，合成文本可在三个受限方向上 useful：脱敏后的客服语料扩写（丰富话术表达）、模型评测样本构造、以公开数据合成“模拟客户提问”用于 prompt 工程验证。需同步框定三条红线：不得以真实个人金融信息训练或微调生成式模型（金融监管已明确禁止）[43]；生成语料用于评测须防止“评测数据与

训练数据同源”造成的虚高；以合成客户数据做产品测试的海外实践属国际媒体报道范畴，国内适用场景与合规路径均不清晰，本报告仅作观察（D 级媒体报道，未采信为案例）。

### （七）场景边界：明确哪些场景暂不应用

为控制合规与声誉风险，除正向场景外，本报告明确列出合成数据现阶段不应主动介入的四类边界场景。其一，自动化决策链路（授信定价、额度调整等直接影响客户权益的环节）：合成数据若进入此类模型的训练与验证，须首先满足《个人信息保护法》关于自动化决策透明公平与人工复核的要求[38]，在合规设计完备前不鼓励引入。其二，对客营销与画像生成：以合成方式构造客户画像用于个性化营销，既面临“大数据杀熟”争议，又可能触发算法推荐与深度合成的标识要求[41][42]，现阶段不主张。其三，监管报送与会计核算：合成数据不得进入任何监管报送、财务报表与审计底稿链路——此类数据的价值在于“真”，合成数据在此场景没有任何合法性空间。其四，跨机构商业数据交换：在国内尚未形成“合成数据可豁免个人信息对外提供审批”的监管共识前，以合成数据向外部机构提供客户相关信息，仍应按个人信息对外提供流程审批（第五章监管映射），不宜以“已合成”为由简化流程。边界清单的作用是把合成数据的应用范围收敛在“内部研发与测试、受控的模型训练增强”等低风险域，与第七章“支撑性组件”定位保持一致。

（八）效益测算（保守 / 中性 / 乐观三档，示意口径）

先说明依据强度。截至编制日，尚无针对“国内股份制银行合成数据应用”的独立公开效益数据。下表数字来自四类来源：行业工程经验（测试数据管理）、学术证据（模型增强类研究）、厂商披露案例（Nationwide 等）与理论推算，其中仅场景 3 有行业级经验支撑、场景 1/2 有学术证据但无银行生产实测，全表无一项达到“同类银行生产实测”水平。以下为示意区间，非收益承诺，须经 POC 实测后校准。

表 8 合成数据在银行业的效益区间测算（示意口径）

| 效益维度          | 保守    | 中性                  | 乐观          | 依据强度 | 数据依据                            |
|---------------|-------|---------------------|-------------|------|---------------------------------|
| 测试数据准备周期缩短    | 20%   | 40%                 | 60%         | 行业经验 | TDM/合成工具自动化程度与行内现状比对（行业经验值，非实测） |
| 长尾/少数类场景识别率改善 | 无明显改善 | 召回提升 5%—15%（AUC 持平） | 召回提升 15% 以上 | 学术证据 | GAN 增强欺诈识别的学术实验[17]；行内真实测试集待验证  |
| 数据获取与标注成本     | 5%    | 10%—15%             | 20%         | 理论   | 减少向外部采买样本与人工造数投入（推              |

| 效益维度         | 保守 | 中性               | 乐观            | 依据强度 | 数据依据                                 |
|--------------|----|------------------|---------------|------|--------------------------------------|
| 本下降          |    |                  |               | 推算   | 算)                                   |
| 外部数据共享/评估周期  | —  | 数月级缩短            | 周级 (6个月→3天量级) | 厂商口径 | Nationwide 案例 (厂商披露, 未获独立第三方验证) [33] |
| 新增平台投入 (一次性) | —  | 数百万元级 (软件+集成+人力) | —             | 参考估算 | 组件化而非平台化的建设口径 (第九章)                  |

注：测算采用“先验证后计量”原则——任何效益行在POC前均为示意，POC验收指标（第四章第（二）、（四）节）通过后，以实测数据替换本表相应行，再作为试点立项依据。回收期口径为“一次性投入 ÷ 年度净效益（效率节省+模型效果改善换算）”，不确定性高，本报告不给出承诺性回收期。

（九）国内外同业落地案例研究

案例筛选标准：仅采信“机构官方披露、权威媒体核实或同行评审文献”三类信源；凡仅见于厂商宣传页或转载内容而

无独立证据的，一律不列为案例证据，列入本章第（九）节的未采信清单。应用阶段按 A 生产 / B 试点或概念验证 / C 研究 / D 厂商自述四级标注。

表 9 国内外合成数据银行相关案例对比表

| 机构                           | 国家 / 地区 | 时间            | 场景                        | 技术         | 应用阶段               | 可验证价值            | 来源与核实状态                 |
|------------------------------|---------|---------------|---------------------------|------------|--------------------|------------------|-------------------------|
| JPMorgan Chase (AI Research) | 美国      | 持续（约 2023 至今） | 金融合成数据集与方法研究，公开发布供学界与产业使用 | GAN/生成式模型类 | C 研究（机构研究部门，非生产披露） | 提供金融合成数据基准与开源数据集 | 机构官网 [34]，公开可查证         |
| Nationwide（英国建房互助协会）         | 英国      | 2020 年起       | 以合成数据支持外部创新伙伴数据评估与数据共享    | Hazy 合成平台  | B—A 试点向生产过渡（机      | 相关流程由 6 个月缩短至 3  | 机构技术博客 [32] + 厂商案例 [33] |

| 机构                                     | 国家 / 地区 | 时间      | 场景                       | 技术                | 应用阶段           | 可验证价值            | 来源与核实状态           |
|----------------------------------------|---------|---------|--------------------------|-------------------|----------------|------------------|-------------------|
|                                        |         |         |                          |                   | 构发文+厂商案例)      | 天<br>(厂商披露口径)    |                   |
| UnionBank<br>(菲律宾联合银行)                 | 菲律宾     | 2025    | 参与“合成数据共享生态(SynDEc)”设计研究 | 生成式AI+共享生态框架      | C 研究           | 验证金融业合成数据共享的可行框架 | 同行评审期刊[35], 公开可查证 |
| Riyad Bank<br>(Jeel 数字创新部)<br>×zypl.ai | 沙特      | 2025年7月 | 合成数据生成与AI风险分析能力合作        | zypl.ai 合成数据+风险分析 | B 试点前(合作备忘录阶段) | 尚无公开量化结果         | 行业媒体[36], 公开可查证   |

| 机构   | 国家 / 地区 | 时间 | 场景 | 技术 | 应用阶段 | 可验证价值            | 来源与核实状态 |
|------|---------|----|----|----|------|------------------|---------|
| 国内银行 | 中国大陆    | —  | —  | —  | —    | 未检索到银行官方披露的生产级应用 | —       |

逐案例说明与可借鉴点。JPMorgan 案例的意义在于证明“头部银行将合成数据视为模型研究与数据供给能力的一部分”——其 AI Research 部门以研究带动方法论沉淀并开放数据集[34]，说明银行不需要先有大规模平台、也可以从方法论与数据基准建设起步；但其性质是研究而非生产，不能作为“生产已落地”的证据。Nationwide 案例是公开资料中较完整的银行侧应用：机构自身技术团队发文说明采用 Hazy 的动因（客户数据不出安全边界、以合成数据对外共享）[32]；其“6 个月到 3 天”的量化出自厂商，属厂商披露口径，本报告仅在标注后引用[33]。可借鉴点是“外部数据评估”这类低

频但审批极重的场景，是合成数据 ROI 最容易被验证的切入口。UnionBank 案例说明合成数据共享正在成为国际银行业的研究前沿，但仍停留在框架验证阶段[35]。Riyad Bank 案例属数字化创新部门与合成数据厂商的能力合作备忘录，阶段最早期，仅作为同业动向信号[36]。

案例小结：将上述案例合并观察，可以得出三个与直觉不同的判断。其一，银行侧证据的“强度”整体偏低——公开可核实的生产级、带量化结果的案例极少，JPMorgan 属研究、Riyad 属合作意向、UnionBank 属学术合作，真正进入生产并披露量化的只有中小型机构（Nationwide）且量化来自厂商。其二，先落地的多是“共享与评估”类轻场景，而非“核心风控建模”重场景，这与第四章场景矩阵的判断一致。其三，国际案例的地理分布显示，欧美监管语境（GDPR 下合成数据作为替代数据共享介质的实践）走在前列，该语境与国内监管环境存在显著差异，国际案例的价值主要是“证明技术可落地”，而非“证明在我行可落地”。

（十一）价值贡献度与战略紧迫度评级依据

表 10 价值贡献度与战略紧迫度评级依据（3 分 / 3 分）

| 评级维度 | 关键点                                     | 定档含义      |
|------|-----------------------------------------|-----------|
| 价值·效 | 测试数据生成场景价值明确、行业经验可量化，为 POC 首选（第四章第（四）节） | 唯一较成熟的价值维 |

| 评级维度     | 关键点                                                                                                                   | 定档含义               |
|----------|-----------------------------------------------------------------------------------------------------------------------|--------------------|
| 率        |                                                                                                                       | 度，可量化              |
| 价值·风控    | 学术证据指向少数类增强可提升召回等指标，但银行生产实测缺乏，须行内真实测试集验证（第四章第（二）节）                                                                    | 有证据、未实证，审慎取值       |
| 价值·合规与共享 | 方向合理，监管认可路径不明，国内无生产案例（第四章第（五）节）                                                                                       | 不作为当前价值依据          |
| 紧迫·技术窗口  | Gartner 持续跟踪并预判 2030 年前后合成数据在 AI 训练数据中占主导、2026 年 75% 企业使用生成式 AI 合成客户数据[19][20]；产业并购密集（2024—2025 年 NVIDIA、SAS）[23][25] | 3—5 年窗口内的能力储备价值明确  |
| 紧迫·同业信号  | 国际银行以研究、试点为主；国内无银行官方生产披露                                                                                              | 先行信号有限，尚未形成必须跟进的倒逼 |
| 紧迫·监管时限  | 无强制采用时限；监管要求聚焦“如何管住生成式 AI 与数据安全”（第五章）                                                                                 | 不构成紧迫性加分           |

综合定档：价值贡献度 3 分（单一维度价值明确可量化，风控维度有学术证据但待实测；理论上存在评 4 分的可能，

待 POC 复评）；战略紧迫度 3 分（3—5 年关键窗口、同业已有先行信号、监管无强制时限）。

五、风险与挑战

（一）监管合规映射

合成数据在银行落地主要牵动三类监管：个人信息与数据安全（生成端真实数据的处理）、算法与内容治理（生成模型的备案与责任）、金融业务专门监管（模型风险与消费者保护）。需强调：截至编制日，国内外均无针对“合成数据”的专门立法；监管评价只能依据既有规则类推。下表将约束落实到具体文件条款。

表 11 合成数据相关监管合规要求映射

| 监管文件                      | 具体条款/要求                                                 | 对合成数据的影响                                               | 风险等级 |
|---------------------------|---------------------------------------------------------|--------------------------------------------------------|------|
| 《个人信息保护法》 <sup>[38]</sup> | 第四条、第十三条：个人信息处理须有合法性基础并遵循最小必要原则；第七十三条：匿名化指无法识别特定个人且不能复原 | 用真实个人信息训练生成模型属个人信息处理；合成数据产品能否主张“匿名化”缺乏明确认可，不得默认“合成即匿名” | 高    |
| 《数据安全法》 <sup>[39]</sup>   | 第二十一条：数据分类分级保护                                          | 生成端真实数据须按分类分级管控；                                       | 中高   |

| 监管文件                              | 具体条款/要求                   | 对合成数据的影响                                     | 风险等级 |
|-----------------------------------|---------------------------|----------------------------------------------|------|
|                                   |                           | 涉重要数据的场景须特别审慎                                |      |
| 《网络数据安全管理条例》 <sup>[40]</sup>      | 敏感个人信息处理要求                | 金融账户等敏感信息用于模型训练须取得单独同意等授权基础，全程在行内安全域内处理      | 高    |
| 《银行保险机构数据安全管理办法》 <sup>[37]</sup>  | 数据处理全生命周期安全、外包与第三方合作管理    | 行内引入合成工具/外部厂商须纳入数据安全评估与外包管理；合成数据对外提供须走数据提供审批 | 中高   |
| 《互联网信息服务算法推荐管理规定》 <sup>[41]</sup> | 算法备案、算法审计、不得利用算法实施不合理差别待遇 | 若合成数据进入对客定价/推荐链路，相关模型与数据须可审计、可解释             | 中    |
| 《互联网信息服务深度合成管理规定》 <sup>[42]</sup> | 深度合成服务提供者须标识生成内容、履行备案义务   | 合成客户画像/文本若面向客户或公开渠道使用，可能触发标识与备案要求            | 中高   |
| 《关于银行业保险业人工智能安全开                  | 个人信息不得用于生成式 AI 模型训练与      | 以 LLM 合成含个人要素的数据受限；                          | 高    |

| 监管文件                                               | 具体条款/要求             | 对合成数据的影响                   | 风险等级      |
|----------------------------------------------------|---------------------|----------------------------|-----------|
| 发应用的指导意见》（金发〔2026〕8号） <sup>[43]</sup>              | 优化；强调可解释与安全评估       | 生成式合成须建立专门安全评估             |           |
| 《征信业务管理办法》 <sup>[44]</sup>                         | 信用信息采集加工须合规、不得变相采集  | 以合成方式构造信用信息用于风控须防止规避征信管理要求 | 中         |
| 中国人民银行《金融领域科技伦理指引》（JR/T 0258—2022） <sup>[45]</sup> | 数据专事专用、最小必要、禁止大数据杀熟 | 合成数据的用途须与授权目的一致，不得跨用途复用    | 中         |
| 《关于构建数据基础制度更好发挥数据要素作用的意见》（数据二十条） <sup>[46]</sup>   | 鼓励数据流通与开发利用         | 属政策鼓励方向的支撑技术，但无豁免性认定       | 低<br>（正面） |

合规映射的总体判断：合成数据不触及“个人金融信息违规出境”等一票否决红线（前提是不把真实个人信息直接灌入境外生成服务），主要风险集中在“生成端数据处理合法性”与“合成产品匿名化属性不被认可”两点；二者均可通过“授权链条核查+生成端数据最小化+差分隐私+不出行内环境”等前置管控措施管理。因此不触发“无可行前置管控”的单列

否决，但决定了银行不能照搬海外“合成即可共享”的轻管控模式。

（三）风险清单（六要素）

表 12 合成数据主要风险清单（六要素）

| 风险项               | 概<br>率 | 影<br>响 | 触发场景                    | 应对措施                       | 责任环节             |
|-------------------|--------|--------|-------------------------|----------------------------|------------------|
| 数据保真度不足           | 中      | 高      | 生成分布与真实分布系统性偏离，模型性能劣化   | 三维质量评估+真实测试集下游验证（第四章）      | 数据与模型工程（牵头），业务验证 |
| 模式崩溃与多样性退化        | 中      | 中      | GAN 训练不稳定，生成样本同质化       | 多基线对比、扩散类替代方案、生成多样性监控      | 模型工程             |
| 偏差放大与公平性风险        | 中      | 高      | 真实数据含历史偏差，合成放大后影响特定客群授信 | 偏差审计、按客群分段评估、敏感属性生成限制      | 模型风险管理+消保        |
| 隐私泄露（成员推断/记忆/重识别） | 中      | 高      | 未加差分隐私的生成模型直接使用真实个人信息   | 差分隐私+对抗性审计+生成端最小化（本章第（二）节） | 数据安全与合规          |
| 模型幻觉/错误生成         | 中      | 中      | LLM 路线生成业务上不可能的字段组合     | 规则校验、业务约束嵌入、生成结果抽检         | 模型工程+业务复核        |

| 风险项           | 概率  | 影响 | 触发场景                   | 应对措施                   | 责任环节        |
|---------------|-----|----|------------------------|------------------------|-------------|
| 监管认可不足与责任边界   | 中   | 高  | 监管不认可“合成即匿名”，共享场景被认定违规 | 授权链条核查、用途限定、不主张匿名化属性   | 合规（牵头），业务协同 |
| 数据血缘断裂与可审计性缺失 | 中   | 中  | 合成数据混入训练集后无法追溯来源与比例    | 血缘元数据管理、生成留痕、混合比例登记    | 数据治理        |
| 供应链与数据投毒      | 低—中 | 中高 | 开源模型/商用服务被植入投毒或合规缺陷    | 供应链评估、本地化部署、版本锁定与安全扫描  | 信息安全+采购     |
| 供应商锁定与算力成本    | 中   | 中  | 依赖单一商用合成平台或云端生成服务      | 开源基线+分层采购+合同开放接口（第九章）  | 科技与采购       |
| 人才与能力缺口       | 中   | 高  | 缺乏生成模型工程与隐私审计复合人才      | 外部引入+工具化降低门槛+内部认证（第九章） | 人才与组织       |

风险清单小结：高频高危项集中在“保真度不足”与“隐私泄露”两类，均非不可管理，但都要求银行先具备质量评估与隐私审计能力——这构成了第九章“评价体系先于平台建设”的直接依据。

（五）引入可行性评级依据

按短板原则，引入可行性按架构/场景改造难度、合规风险、安全风险、人才门槛四项子要素分别评级，取最低分定档。

表 13 引入可行性四子要素评级（短板原则）

| 子要素       | 评级 | 依据                                                             |
|-----------|----|----------------------------------------------------------------|
| 架构/场景改造难度 | 4分 | 可作数据中台内组件增量引入，测试数据与建模流程改动可控，无需颠覆性架构改造；但需打通脱敏、血缘与模型平台           |
| 合规风险      | 3分 | 不触及出境等一票否决红线；但“合成即匿名”不被认可、生成端数据处理与算法治理要求叠加，需专项合规设计与审查（本章第（一）节） |
| 安全风险      | 3分 | 新增生成模型供应链与隐私记忆攻击面，须差分隐私与对抗性审计前置；总体存在成熟管控手段，需专项投入               |
| 人才门槛      | 3分 | 生成模型工程与隐私审计复合人才稀缺，但开源工具链成熟、外部厂商供给充分，可通过“少量专家+工具化+厂商合作”组合缓解     |

引入可行性综合评级：3 分（四项子要素最低者为 3 分，各子要素风险与成本总体可管理，需专项投入与治理）。该结论与“先 PoC、不建平台”的研究层处置一致——引入并非不可行，而是需要受控地、分阶段地推进。

六、市场格局与竞争生态

（一）全球市场规模：多来源交叉验证与口径说明

本次研究对六家机构进行了横向核验，六家机构口径对比如下：

表 14 全球合成数据市场多机构规模预测对比（单位：亿美元）

| 机构                                           | 基准<br>年与<br>规模    | 预测期<br>末年与<br>规模 | CAGR                      | 统计口径特征                                                |
|----------------------------------------------|-------------------|------------------|---------------------------|-------------------------------------------------------|
| Grand View<br>Research <sup>[26]</sup>       | 2023<br>年<br>2.18 | 2030 年<br>17.88  | 35.3%<br>(2024—<br>2030)  | 合成数据生成<br>(SDG) 市场，含<br>表格/文本/图像视<br>频等数据类型的软<br>件与服务 |
| Mordor<br>Intelligence <sup>[27]</sup>       | 2025<br>年<br>5.10 | 2031 年<br>36.7   | 38.96%<br>(2026—<br>2031) | 合成数据市场，按<br>技术 (GAN/扩散<br>等)、形态 (完全<br>/混合合成) 细分      |
| Fortune Business<br>Insights <sup>[28]</sup> | 2026<br>年<br>7.91 | 2034 年<br>69.05  | 31.10%<br>(2026—<br>2034) | 合成数据生成市<br>场，含平台、软件<br>与服务                            |
| Precedence<br>Research <sup>[29]</sup>       | 2025<br>年<br>5.85 | 2035 年<br>107.80 | 33.84%<br>(2026—<br>2035) | 口径偏宽 (含更广<br>生成数据应用)                                  |

| 机构                                        | 基准<br>年与<br>规模    | 预测期<br>末年与<br>规模 | CAGR                     | 统计口径特征                         |
|-------------------------------------------|-------------------|------------------|--------------------------|--------------------------------|
| Research and<br>Markets <sup>[30]</sup>   | 2026<br>年<br>9.20 | 2030 年<br>30.20  | 34.5%                    | 合成数据市场<br>(2026 年报告)           |
| Market Research<br>Future <sup>[31]</sup> | 2025<br>年<br>7.71 | 2035 年<br>346.2  | 46.3%<br>(2025—<br>2035) | 口径最宽(含多模<br>态与仿真数据),<br>明显高于同业 |

结论：全球合成数据市场基数小、增速高（2025—2026 年约 5 亿—10 亿美元，2030 年主流预测 18 亿—35 亿美元），各机构差异主要来自统计口径，不宜对比绝对值；银行相关的表格合成为主要细分，技术代际正向扩散模型与大模型迁移<sup>[26][27]</sup>。国内沙利文口径折算后量级一致，仅作参考<sup>[50]</sup>。

对银行决策而言，市场规模绝对值参考意义有限，关键信号有三：表格合成是收入占比较高的细分、技术代际正从 GAN 向扩散与大模型迁移、能力正被并入大厂数据与 AI 平台<sup>[26][27]</sup>。这支持低成本跟进，不支持据此做大额投入。

（二）行业结构与 Porter 五力分析

行业结构小结：市场处于“多路并存、加速整合”的早期成长阶段，2024—2025 年 NVIDIA 收购 Gretel、SAS 收购

Hazy 两起并购表明行业正从“独立创业公司”向“嵌入大厂数据与 AI 栈”演进<sup>[23][25]</sup>。Porter 五力逐项评级分析如下：

供应商议价能力中等：算力与基础模型供给集中（GPU、云与基础大模型），但合成算法本身开源充分，单一供应商难以形成强议价。

购买者议价能力中等偏强：银行作为大客户有较强议价力，但合格的专业实施方与复合型人才供给有限，优质服务仍稀缺。

潜在进入者威胁高：开源工具降低了算法门槛，云厂商、数据分析厂商、隐私计算厂商均可横向切入，2024—2025 年并购即是进入方式之一。

替代品威胁中等偏高：对银行而言，数据脱敏增强、隐私计算与更高质量的真实数据治理可在相当程度上替代合成数据的部分用途，这是合成数据在银行侧最主要的外部竞争力量。

行业内竞争强度中等：独立厂商间直接竞争激烈（Mostly AI、Tonic、YData、Syntho 等），但产品差异化尚未定型，客户切换成本总体可控。




图 3 合成数据行业 Porter 五力结构示意图（自绘）

对银行的启示：供给端已从“要不要有合成数据”过渡到“在哪个平台能力上获得合成数据”，银行应把选型问题从“选哪家厂商”升级为“如何在自己数据栈中按需启用合成能力”，以避免在行业整合期押注单一厂商（第六章第（四）节生态开放度评级呼应）。

### （三）主要厂商与开源生态格局

厂商格局按“并购整合者—专业厂商—开源生态—云平台—国内参与者”五类梳理如下。

表 15 合成数据主要厂商/方案格局一览

| 类别 | 厂商                           | 国别 | 代表性能力              | 金融适配与核实状态  |
|----|------------------------------|----|--------------------|------------|
| 并购 | NVIDIA（收购 Gretel，2025 年 3 月） | 美国 | 合成数据平台并入 AI 基础设施栈； | 引擎层供给方；事件经 |

| 类别    | 厂商                                           | 国别    | 代表性能力                                | 金融适配与核实状态                              |
|-------|----------------------------------------------|-------|--------------------------------------|----------------------------------------|
| 整合者   |                                              |       | 配套 Nemotron（文本合成）、Cosmos（世界模型/仿真数据）等 | 权威媒体核实 <sup>[23][24]</sup>             |
| 并购整合者 | SAS（收购 Hazy 核心软件资产，2024 年 11 月）              | 美国/英国 | 在数据与 AI 分析组合中内置合成数据生成                | 其客户群含银行保险；事件经官方与媒体报道核实 <sup>[25]</sup> |
| 开源生态  | SDV/DataCebo（源自 MIT）                         | 美国    | SDV 工具库及 CTGAN、TVAE 等表格合成算法，开源协议分发   | 事实性社区标准，银行 PoC 首选基线 <sup>[10]</sup>    |
| 开源生态  | ydata-synthetic、DataSynthesizer、Gretel 开源组件等 | 多国    | 各类表格/时序合成与差分隐私合成参考实现                 | 社区工具，可按 Apache 2.0 等协议本地化使用            |
| 专业厂商  | Mostly AI                                    | 奥地利   | 面向企业的表格/文本合成平台与评测                    | 多行业宣传有金融客户，生产案例未见独立第三方验证               |
| 专     | Tonic.ai                                     | 美     | 开发与测试数据合                             | 主要面向软                                  |

| 类别   | 厂商                                         | 国别        | 代表性能力                   | 金融适配与核实状态                                  |
|------|--------------------------------------------|-----------|-------------------------|--------------------------------------------|
| 业厂商  |                                            | 国         | 成（含数据库子集化）              | 件工程场景，宣称服务金融                               |
| 专业厂商 | YData、Syntho、Statice                       | 葡萄牙/荷兰/德国 | 表格合成、数据开发平台与差分隐私合成      | 以欧洲金融客户宣传为主                                |
| 专业厂商 | zyp1.ai                                    | 波兰        | 合成数据生成+AI风险分析           | 与 Riyadh Bank Jeel 签署合作备忘录 <sup>[36]</sup> |
| 云平台  | Microsoft Azure、AWS、Google Cloud；国内阿里云、华为云 | 跨国/中国     | 在数据与 AI 平台中提供数据合成/生成类能力 | 平台级供给，银行可按云上数据合规要求评估                       |
| 国内参与 | 翼方健数、富数科技、洞见科技等隐私计算/数据安全厂商                 | 中国        | 隐私计算平台附带合成数据能力          | 厂商宣传（D级）；未检索到国内银行官方披露                      |

| 类别 | 厂商 | 国别 | 代表性能力 | 金融适配与核实状态 |
|----|----|----|-------|-----------|
| 者  |    |    |       | 的生产级案例    |

格局判断有三点。第一，行业正处于“创业公司并入大厂”的整合期，Gretel、Hazy 先后被收购，独立厂商的价值主张正从“卖合成软件”转向“提供垂直行业数据方案”。第二，开源工具（尤其 SDV 系）构成生态底座，使银行可以低成本启动 PoC 而不被早期厂商锁定；同时开源的广泛可用也压低了专业厂商的算法溢价，专业厂商的差异化转向“差分隐私、企业治理、行业 Know-how”。第三，国内供给以隐私计算厂商的附带能力为主，“合成数据”鲜有独立产品表述，且普遍缺少银行生产级验证；银行如引入，应把国内厂商方案与开源基线做同口径评测，而不宜以厂商宣传替代评测。

#### （四）生态开放度评级依据

表 16 生态开放度评级依据（评级：4 分）

| 子维度   | 现状事实                                                                          | 指向      |
|-------|-------------------------------------------------------------------------------|---------|
| 开源与标准 | 核心算法开源充分（SDV/CTGAN/TVAE 等），多基于 Apache 2.0 等开放协议 <sup>[10]</sup> ；生成模型本身无强专有锁定 | 不构成技术锁定 |
| 供应    | 开源、专业厂商、云平台、并购整合者多路并                                                          | 买方有选择   |

| 子维度    | 现状事实                                                | 指向             |
|--------|-----------------------------------------------------|----------------|
| 商格局    | 存，2024—2025 年并购加速但未形成寡头                             | 与替换空间          |
| 国产化适配  | 开源工具可本地化部署适配信创环境；国内厂商有隐私计算+合成方案；但银行生产验证空白，国产化成熟度待验证 | 存在国产化路径，尚未充分验证 |
| 替代方案成本 | 数据脱敏、隐私计算、真实数据治理提供部分替代路径（第五章），主流工具迁移成本低             | 替代与迁移成本可控      |

评级说明：生态开放度评 4 分，理由是以开放标准与开源为主、多厂商可选、具备国产化适配路径，但需扣分项有二：一是生成质量与隐私评估尚无统一标准（影响互操作与可比性）；二是部分能力（差分隐私工程、大模型底座）仍依赖少数头部供应商。综合取 4 分，不触发供应链依赖预警。

第六章小结：市场规模仍小但高增长，行业处于整合早期；对银行而言，供给侧的成熟度足以支撑“低成本 PoC”，尚不足以支撑“基于单一厂商的平台化建设”。生态开放度高，为银行提供了以开源基线保持主动权的窗口期。

## 七、战略定位与匹配度

### （一）与我行战略的关系

我行当前以“数智化战略”为统领，数智贯通“客户经营、数据管理、智能运营、产品创新、风险管理”五大体系，并发布《人工智能实施行动计划（2026）》，将 AI 能力建设提升至战略核心地位<sup>[47]</sup>。合成数据与两项战略主张直接相关：其一，“数据管理”体系下的数据资产化与数据要素价值释放——合成数据作为数据供给与数据流通的支撑组件，可服务于“让数据资产用起来”的目标；其二，AI 能力建设的底层供给——无论垂类大模型还是智能体应用，都需要足量、合规的训练、评测与测试数据，合成数据是 AI 数据工程链路的组成部分。

但必须精确校准其战略位阶。我行 2025 年年报明确：发布《人工智能实施行动计划（2026）》，将 AI 能力建设提升至战略核心地位，打造金融垂类大模型与智能体<sup>[47]</sup>；公开披露层面则以“浦银智启”大模型服务矩阵（GLM5.1 与 DeepSeek-V4 部署应用、表单识别/财务分析/行业分析等标杆垂类模型）作为 AI 应用的落地抓手<sup>[47]</sup>。合成数据未被列入该计划点名的核心建设对象，它属于上述 AI 建设主线及数据管理体系之下的“使能型技术路径之一”，而非并列的战略赛道。据此，战略匹配度评 3 分（评级依据见本节（四））。

## （二）与企业架构的关系

合成数据能力的建设不独立成平台，全流程纳入我行“5A4S”企业级架构管控：数据底座层复用现有数据中台与数据治理体系，算法与工程能力沉淀在“数智能力中心”及相关数据能力域，对外以服务形式嵌入数据开发、模型训练与测试环境管理流程。与现有系统呈“互补嵌入”关系：脱敏与访问控制仍是真实数据第一道闸，合成能力作为供给组件并行，不改动核心系统与数据模型。十大业务能力中心中，数智能力中心为主要建设方，风控、运营、科技相关中心为主要使用方；客户经营中心在涉及合成客户数据的分场景中为使用方。映射关系在执行阶段以企业架构评审为准，本报告不作扩大化表述。

## （三）SWOT 分析

表 17 合成数据在我行的 SWOT 分析

| 维度        | 内容                                                                                     | 策略转化                                      |
|-----------|----------------------------------------------------------------------------------------|-------------------------------------------|
| 优势<br>(S) | 1. 数据资产规模大、治理体系较完善，具备合成学习的真实数据基础；2. 已有成熟数据中台、AI 平台与模型风险管理流程可承接组件；3. 风控、研发测试等场景痛点真实且可量化 | SO：以开源工具在既有平台上做低成本 POC，把“数据资产”转化为“数据供给能力” |
| 劣势<br>(W) | 1. 生成模型工程与隐私审计人才不足；2. 合成数据质量评估方法与评测基线空白；3. 真实数据血缘与授权管理仍需补课                             | WO：借 PoC 沉淀方法论与评测基线，同步补数据就绪度短板            |

| 维度        | 内容                                                                                                                                      | 策略转化                                 |
|-----------|-----------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------|
| 机会<br>(O) | 1. 生成式 AI 与我行大模型战略叠加，数据供给需求上升 <sup>[47]</sup> ；2. 开源与商用工具成熟、生态开放度高（第六章）；3. 同业尚未规模化，先验证者可沉淀方法论                                           | WO/ST：以研究层定位抢在窗口期建立评测与治理先发能力，不押注平台规模 |
| 威胁<br>(T) | 1. 合成数据不被监管认可为“匿名”，合规路径不确定（第五章）；2. 脱敏增强、隐私计算与数据治理改进可部分替代其价值（第五章）；3. 技术路线快速迭代，存在沉没成本风险；4. 全行 AI 资源优先投向垂类大模型与智能体，内部资源竞争激烈 <sup>[47]</sup> | WT：不建独立平台、不押注单一技术路线，以可中止的 PoC 控制下行风险 |

#### （四）战略匹配度评级依据

表 18 战略匹配度评级依据（评级：3 分）

| 判定项       | 要点                                                                             | 对分值的影响      |
|-----------|--------------------------------------------------------------------------------|-------------|
| 战略方向命中    | 命中“数智化”战略下数据管理体系与 AI 能力建设方向，属该方向的技术路径之一 <sup>[47]</sup>                        | 满足 3 分档基本判据 |
| 未列入点名建设主线 | 我行《人工智能实施行动计划（2026）》点名打造的 AI 建设主线为“金融垂类大模型与智能体” <sup>[47]</sup> ，合成数据未被列入核心建设对 | 不足以评 4 分及以上 |

| 判定项       | 要点                                 | 对分值的<br>影响     |
|-----------|------------------------------------|----------------|
| 的原因       | 象；属支撑性/使能型组件                       |                |
| 多方向<br>协同 | 可同时服务数据管理、风控建模、研发效能等多个方向，但均为“路径之一” | 不产生升档效应        |
| 现实加分项     | 与数据治理、模型风险管理等既有体系直接衔接，PoC 即有当下价值   | 支撑研究层内排队，不改变分值 |

综合定档：战略匹配度 3 分——命中战略方向清单中的方向、是该方向下的技术路径之一，但未被纳入《人工智能实施行动计划（2026）》点名打造的 AI 建设主线。

### 八、综合评估结论

#### （一）六维评级汇总

表 19 合成数据六维评级汇总

| 评估<br>维度      | 分<br>值 | 评级依据（一句话）                                                               |
|---------------|--------|-------------------------------------------------------------------------|
| 技术<br>成熟<br>度 | 3<br>分 | 通用工具链较成熟、多行业有生产案例，但银行表格合成域仍处有限试点、标准未成，Gartner 仍以新兴技术定位跟踪（评级口径见第三章第（七）节） |
| 战略<br>匹配      | 3<br>分 | 命中“数智化”数据管理与 AI 建设方向，属其技术路径之一；不在《人工智能实施行动计划（2026）》点名的 AI                |

| 评估<br>维度      | 分<br>值 | 评级依据（一句话）                                                  |
|---------------|--------|------------------------------------------------------------|
| 度             |        | 建设主线之列（第七章第（四）节）                                           |
| 价值<br>贡献<br>度 | 3<br>分 | 测试数据场景价值可量化，风控增强有学术证据待行内实测，合规共享证据不足（审慎取 3，POC 后复评）         |
| 引入<br>可行<br>度 | 3<br>分 | 可组件化增量引入，合规与安全风险有前置管控手段，人才为短板但可控（短板原则，第五章第（五）节）            |
| 战略<br>紧迫<br>度 | 3<br>分 | 3—5 年关键窗口：Gartner 预判与产业并购信号明确，同业以研究/试点为主，监管无强制时限（第四章第（十）节） |
| 生态<br>开放<br>度 | 4<br>分 | 开源为主、多厂商可选、国产化路径存在；质量标准与部分底层能力仍集中（第六章第（四）节）                |

六维评分不做加权求和。雷达图示意图见下图（自绘，六顶点自正上方起顺时针依次为技术成熟度、战略匹配度、价值贡献度、引入可行度、战略紧迫度、生态开放度）。

合成数据六维评估（1—5分；结论按处置档位组合判据推导，非加权平均）




图 4 合成数据六维评估雷达图（自绘）

## （二）处置档位推导

对照处置档位映射规则的组合判据：布局层要求战略匹配度与价值贡献度均不低于 4 分且技术成熟度 2—3 分——本报告战略匹配度、价值贡献度均为 3 分，不满足；论证层要求战略匹配度与价值贡献度均不低于 4 分且技术成熟度 4—5 分——同样不满足；研究层判据为“四个维度中至少一维处于 3 分附近的关键不确定，且趋势明确但尚待判明”——本报告战略匹配度、价值贡献度、技术成熟度、引入可行性均处于 3 分附近，技术趋势明确（Gartner 持续跟踪、产业并购、方法代际演进）但银行域价值与合规路径尚待实证，符合研究层特征。综合结论：合成数据处置档位为“深入研究（研究层）”，战略紧迫度 3 分，在层内优先排期。

否决线与预警核查：不涉及个人金融信息或重要数据违规出境，未触发《数据安全法》《个人信息保护法》相关强制红线的直接适用情形（前提约束见第五章第（一）节）；生态开放度 4 分，不触发供应链依赖预警；引入可行度 3 分、存在可行前置管控手段，不触发单列否决。故按组合判据正常推导定档。

核心建议：现阶段不宜建设独立合成数据平台，不启动跨条线规模化推广；建议以“组件化能力+双场景 POC”切入：0—6 个月完成两个 POC（测试数据生成、风控少数类增强）并建立含真实测试集的评测基线；POC 达标（第九章阈值）则按“试点扩展→组件化嵌入数据中台”路径推进并申请升级为论证层；未达标则止损并将产出（评测方法论、工具测评结论、数据就绪度清单）沉淀为数据工程能力，投入不白费。

待验证前提（触发重评条件）。其一：若 12 个月内出现 2 家以上可比银行的公开生产级合成数据案例并披露量化效果，或监管机构（人民银行/金融监管总局/国家数据局）就合成数据质量或匿名化属性出台专门指引，应重评技术成熟度与战略紧迫度并可能升级至论证层；其二：若我行 PoC 显示合成增强在真实测试集上无增量收益，或质量评估成本高于预期，应维持观察层动作并缩小范围。监控周期为半年。

九、实施建议

（一）总体思路：组件化引入，不做独立平台

综合前文判断，合成数据在我行的实施总纲是四句话：评价体系先于生成工具；真实测试集作最终裁判；脱敏够用就不上合成；合成能力作为数据中台组件渐进沉淀。据此，不建议设置“合成数据平台”独立项目，而建议在既有数据中台与AI 平台能力框架内增设“数据合成与评估”组件，按“场景POC→试点→组件化”三段推进，每段设置可量化门槛，未达标即止损。

（二）分阶段实施路径与里程碑

表 20 分阶段实施路线图（0—36 个月）

| 阶段                        | 时间窗口   | 核心任务                                                     | 可考核里程碑                              | 退出/止损标准                                               |
|---------------------------|--------|----------------------------------------------------------|-------------------------------------|-------------------------------------------------------|
| 第一阶段：<br>工具测评与<br>双场景 POC | 0—6 个月 | 1. 完成数据就绪度评估（本章第（四）节清单），盘点可用于合成学习的真实数据资产；<br>2. 建立合成数据评测 | 工具测评报告完成；两场景 PoC 报告完成；差分隐私与隐私审计基线建立 | 场景 A 若数据准备效率无实证提升、场景 B 若合成增强在真实测试集上无长尾分段改善，则中止对应场景并归档 |

| 阶段 | 时间窗口 | 核心任务                                                                                                                        | 可考核里程碑 | 退出/止损标准 |
|----|------|-----------------------------------------------------------------------------------------------------------------------------|--------|---------|
|    |      | 基线：选定真实测试集（不掺合成样本）与指标协议（AUC、KS、Recall、误报率、数据准备工时）；3. 以开源工具（SDV/CTGAN/TVAE等）为主、辅以 1—2 家商用方案，完成同口径工具测评；4. 场景 A：测试数据生成 PoC（选 1 |        | 方法论     |

| 阶段               | 时间窗口    | 核心任务                                                                                 | 可考核里程碑                               | 退出/止损标准                                     |
|------------------|---------|--------------------------------------------------------------------------------------|--------------------------------------|---------------------------------------------|
|                  |         | 个核心系统<br>非生产环境）； 5.<br>场景 B：风控少数类增强 PoC（选 1 个高价值评分/预警模型）； 6.<br>对厂商与开源方案执行成员推断与重识别抽查 |                                      |                                             |
| 第二阶段：<br>试点与规范沉淀 | 6—18 个月 | 1. 视第一阶段结果将达标场景扩展至 1—2 个条线有限试点； 2.<br>建立行内合成数据质量评估规范（保真度/                            | 行内评估规范与使用清单发布；试点场景季度复盘报告；模型风险审计无红线问题 | 合规审查无法通过或审计发现未受控泄露场景，暂停并整改；试点量化收益未达预期则退回研究层 |

| 阶段                      | 时间窗口     | 核心任务                                                                                    | 可考核里程碑                   | 退出/止损标准                   |
|-------------------------|----------|-----------------------------------------------------------------------------------------|--------------------------|---------------------------|
|                         |          | 效用/隐私三维，附录一说明口径）；3. 将差分隐私预算、成员推断审计、数据血缘登记纳入数据与模型风险管理流程；4. 沉淀合成数据使用与禁用清单（哪些场景脱敏优先、哪些可合成） |                          |                           |
| 第三阶段：<br>组件化嵌入<br>与自助服务 | 18—36 个月 | 1. 将合成引擎、评估组件、隐私审计能力嵌入数据中台                                                              | 合成能力组件上线并纳入平台目录；自助式生成流程有 | 若出现监管新规禁止/限制合成数据用于特定用途，触发 |

| 阶段 | 时间窗口 | 核心任务                                                                                    | 可考核里程碑                | 退出/止损标准      |
|----|------|-----------------------------------------------------------------------------------------|-----------------------|--------------|
|    |      | 与 AI 平台，开放配置化、自助式生成服务；2. 与大模型战略衔接：开展文本语料与评测数据合成的受限试点（严格合规前置）；3. 跟踪扩散模型与超合成数据进展，按需升级技术路线 | 明确授权与审计；年度数据安全与合规审计通过 | 范围收缩并重评本技术储备 |




图 5 三阶段实施路线图与关键决策点（自绘）

### （三）POC 设计要点与验收协议

POC 的具体选型、指标口径与验收阈值待立项后专项规划，本报告仅明确两条纪律：真实测试集独立封存、不以合成数据自评；隐私审计前置。具体方案由科技发展部牵头会同数据经营与管理部及法律合规部制定。

### （四）启动前提条件：数据就绪度评估清单

PoC 启动前，组织、数据、合规三方面的就绪情况应逐项评估，作为立项审议的必备材料。与 POC 直接相关的硬条件是数据就绪度，评估清单如下。

表 21 数据就绪度评估清单

| 检查项      | 优先级  | 评估标准         | 不具备时的影响      |
|----------|------|--------------|--------------|
| 真实数据分类分级 | 核心必要 | 已完成个人信息与业务数据 | 无法界定哪些数据可用于生 |

| 检查项        | 优先级  | 评估标准                                        | 不具备时的影响                                                    |
|------------|------|---------------------------------------------|------------------------------------------------------------|
|            |      | 分类分级，资产目录覆盖主要建模数据域                          | 成学习、哪些须先行脱敏                                                |
| 授权与合法性基础   | 核心必要 | 目标数据的使用已具备授权基础与用途登记                         | 以真实数据训练生成模型可能违反个保法要求                                       |
| 脱敏与最小化机制   | 核心必要 | 生成训练前可执行最小化与去标识化处理，处理全流程在行内安全域              | 直接使用原始个人信息训练生成模型，触碰金发<br><br>(2026) 8 号与数据安全要求<br>[43][39] |
| 真实测试集与评测基线 | 核心必要 | 拥有独立封存、覆盖长尾的真实测试集及指标口径<br>(AUC/KS/Recall 等) | 无法回答“合成是否真的有用”，价值论证落空                                      |
| 数据血缘与版本管理  | 重要   | 具备数据集版本、来源与加工记录管理能                          | 合成样本混入后无法追溯，模型风险管理                                         |

| 检查项     | 优先级 | 评估标准                          | 不具备时的影响              |
|---------|-----|-------------------------------|----------------------|
|         |     | 力                             | 与审计受阻                |
| 算力与工程环境 | 重要  | 具备 GPU 训练或云端受限环境              | 生成模型训练与评测周期不可控       |
| 隐私审计工具  | 重要  | 具备或可引入成员推断/重识别测试工具链           | “隐私安全”无从验证，第五章风险不可管理 |
| 复合型人力   | 重要  | 至少 2—3 名可投入的建模+数据工程人员（可含外部专家） | POC 质量与周期无保障         |

用法建议：核心必要项不具备的，先补数据基础再启动 POC；重要项不具备的，可在 POC 内受限同步建设。

### （五）Build vs Buy：按组件分层决策

合成数据建设的总体原则是“开源打底、商购补强、方法论自研”，避免两端的极端策略——既不宜全部自研生成算法（迭代快、投入大），也不宜整套外购平台（行业整合期存在锁定风险）。按组件战略价值分层决策如下。

表 22 自建还是外购分层决策

| 组件             | 决策    | 具体方案                                           | 决策理由                         |
|----------------|-------|------------------------------------------------|------------------------------|
| 基础合成算法<br>(表格) | 开源    | SDV/CTGAN/TVAE 等，Apache 2.0 等开放协议本地化部署<br>[10] | 算法本身非差异化壁垒，开源为事实标准、成本低、可审计   |
| 质量评估与评测协议      | 自研    | 建立行内三维评估规范与真实测试集评测基线                           | 评估方法论是行内可复用资产，也是厂商无法替代的核心能力  |
| 差分隐私与隐私审计      | 商购+开源 | 差分隐私合成引擎可商购成熟产品；成员推断等审计工具链开源+自研封装              | 隐私工程门槛高、责任重，成熟产品经多场景验证，自研风险大 |
| 商用合成平台         | 暂缓采购  | PoC 阶段仅按需试用 1—2 家，不承诺长期 license                | 行业整合期厂商格局未定（第六章），先验证价值再谈选型   |
| 文本/大模型相关合成     | 跟随评估  | 依托我行大模型能力底座做受限试点，不                             | 与我行垂类大模型战略重叠，避免重复            |

| 组件        | 决策   | 具体方案                 | 决策理由               |
|-----------|------|----------------------|--------------------|
|           |      | 单独建设                 | 投资 <sup>[47]</sup> |
| 引擎集成与平台组件 | 自研集成 | 将合成/评估/审计能力封装为数据中台组件 | 集成与治理属行内能力，须自主可控   |

采购约束：外采合同须要求开放 API、数据导出与本地化部署选项，商用方案须通过隐私抽查方可进入 POC。

#### （六）组织协同与持续跟踪

建议由科技发展部牵头，联合数据、风控、合规条线组成虚拟团队推进，每半年重检一次监管、同业与 POC 进展，触发重评条件即复评处置档位。

#### （七）投入测算与依赖项管理

投入采用“组件化口径”测算而非平台口径。第一阶段（0—6 个月）以人力与算力为主：建议 2—3 名建模/数据工程人员（可含外部顾问）+GPU 训练与评测环境+开源工具链，一次性投入控制在百万元级，不安排合成平台 license 采购；第二阶段（6—18 个月）视 POC 结果决定是否采购差分隐私等商用组件，采购须满足本章第（五）节的合同约束；第三阶段（18—36 个月）的组件化建设并入数据中台既有预算盘子，不单列大额资本支出。OpEx 方面，生成训练与评测的持续算

力、模型版本维护与合规审计构成主要运维成本，须在试点立项时给出逐年区间并纳入 ROI 跟踪。

依赖项管理是实施计划中易被忽视但实际影响最大的环节。本路线图的关键外部依赖包括：数据中台是否按期开放目标数据域的受控访问接口（供生成训练使用）；模型平台是否支持四组对照评测所需的实验隔离与指标采集；GPU 与算力资源池的可用配额；合规部门对差分隐私预算与隐私审计工具的评审排期；以及监管口径若有更新（如金融监管总局对生成式 AI 数据使用的新规）时的预案。任一项依赖延迟超过一个季度，对应阶段里程碑应顺延并同步知会决策层，而非以压缩评测质量换进度。每阶段均设有量化退出标准（表 20 与本章第（三）节），执行中由科技部牵头按季度向技术管理委员会汇报 go/no-go 结论，确保投入可中止、止损有依据。

## 附录一 研究方法数据来源

### A.1 研究方法

本报告综合采用四种方法：其一，文献研究——系统检索合成数据的经典与前沿学术文献（覆盖生成对抗网络、变分自编码器、扩散模型、大语言模型表格生成、差分隐私合成、成员推断攻击与模型崩溃等主题），并梳理 Gartner、市场研究机构与监管机构的公开材料；其二，案例调研与证据分级——收集国内外金融机构与厂商的合成数据应用信息，按“A 生产

应用 / B 试点或概念验证 / C 研究或实验 / D 厂商自述且无独立证据”四级分类采信，凡无法核实的案例一律列入未采信清单而非正文证据；其三，联网核实——对市场规模、Gartner 表述、并购事件、监管文件文号与施行日期、银行披露信息等关键事实逐一经公开渠道核实，并区分官方原文与第三方转引；其四，专家研判——基于银行业科技与数据管理实践，结合我行定期报告披露内容，对成熟度、价值、可行度等维度作出判断。

## A.2 数据来源

主要来源渠道包括（除注明外均为公开可查证信源）：权威学术文献（NeurIPS、ICLR、USENIX Security、Nature、IEEE、ACM、Elsevier 等出版的论文）；Gartner 公开条目与会员文档摘要；市场研究机构报告公开页（Grand View Research、Mordor Intelligence、Fortune Business Insights、Precedence Research、Research and Markets、Market Research Future 等）；监管与官方机构公开文件（国家金融监督管理总局、国家网信办、中国人民银行、国务院、美国人口普查局等）；厂商官方发布（NVIDIA、SAS、J.P. Morgan AI Research、Nationwide 技术博客等）；行业媒体（TechCrunch、WIRED、Global Banking Monitor 等）与我行定期报告。

## A.3 市场数据处理方法

全球市场规模采用多来源交叉验证，不采信单一机构预测。处理规则：①逐机构记录基准年、期末年、规模与 CAGR，不混用不同基准年的数字；②以机构自身公开口径核对市场定义（是否含平台/软件/服务、是否含图像/3D 仿真与更广义数据），并据此解释机构间差异；③对明显偏离同业区间的极端值（如个别来源 2035 年数百亿美元预测）保留并说明其口径，不作隐去。

#### A.4 评级方法与评分口径

六维评级执行行内撰写规范：技术成熟度=Hype Cycle 定位+TRL 就绪度+生产案例+标准成熟度；引入可行性按架构改造难度、合规风险、安全风险、人才门槛四项子要素取短板；综合结论按“处置档位映射规则”推导，不做六维加权。需披露的口径调整：技术成熟度以“银行可用性”为目标域取 3 分——通用合成算法与工具链已接近 4 分档，但银行表格合成域标准化与生产证据不足；价值贡献度审慎取 3 分（理论上存在评 4 分空间），待 POC 实测后复评。以上均为本报告自设的审慎约束，非撰写规范强制要求，特此披露。

#### A.5 局限性说明

其一，市场机构预测数字因口径与模型差异显著，仅作趋势参考，不作为投资测算依据；其二，国际案例的量化效果（如 Nationwide 案例）多来自厂商披露，未获独立第三方验证，正文已明确标注；其三，国内银行合成数据生产级案例缺

失，本报告对国内部分的结论是“无证据”而非“不存在”，存在信息不对称下的误判可能；其四，监管规则对合成数据无专门规定，合规分析基于既有规则类推，不构成法律意见；其五，Gartner 相关曲线原图未取得合法授权来源，未随文嵌入，相关定位分析基于公开文字材料。

附录二 名词解释

表 23 名词解释术语表

| 术语/缩写                    | 中文全称   | 英文全称                     | 简明释义                        |
|--------------------------|--------|--------------------------|-----------------------------|
| Synthetic Data           | 合成数据   | Synthetic Data           | 不直接来自真实事件、由算法按真实数据统计规律生成的数据 |
| Fully Synthetic Data     | 完全合成数据 | Fully Synthetic Data     | 全部字段由模型生成、不保留真实记录字段的数据      |
| Partially Synthetic Data | 部分合成数据 | Partially Synthetic Data | 仅敏感字段被合成替换、其余字段保留真实值的数据     |
| Hybrid Synthetic         | 混合合成数据 | Hybrid Synthetic         | 真实样本与生成样本按比例                |

| 术语/缩写                       | 中文全称   | 英文全称                        | 简明释义                       |
|-----------------------------|--------|-----------------------------|----------------------------|
| Data                        |        | Data                        | 混合构成的数据集                   |
| Conditional Generation      | 条件生成   | Conditional Generation      | 在指定属性（客群、风险等级等）条件下定向生成样本   |
| Mode Collapse               | 模式崩溃   | Mode Collapse               | 生成模型退化为只输出少量样本形态、多样性丧失的现象  |
| Differential Privacy        | 差分隐私   | Differential Privacy        | 通过校准噪声使单条记录对输出影响有界的可证明隐私框架 |
| Membership Inference Attack | 成员推断攻击 | Membership Inference Attack | 推断某条记录是否属于模型训练数据的攻击方式      |
| Model Inversion             | 模型反演   | Model Inversion             | 利用模型输出反推训练样本敏感属性的攻         |

| 术语/缩写                      | 中文全称   | 英文全称                                 | 简明释义                            |
|----------------------------|--------|--------------------------------------|---------------------------------|
|                            |        |                                      | 击方式                             |
| Re-<br>identification<br>n | 重识别    | Re-<br>identification<br>n           | 结合背景知识<br>把合成/脱敏记录重新链接到<br>真实个体 |
| Fidelity                   | 保真度    | Fidelity                             | 合成数据与真实数据在分布<br>与关联上的一致程度       |
| Utility                    | 效用     | Utility                              | 合成数据在下游任务（建模、测试）中的可用性表现         |
| Privacy                    | 隐私     | Privacy                              | 数据不泄露真实个体可识别信息的程度               |
| GAN                        | 生成对抗网络 | Generative<br>Adversarial<br>Network | 生成器与判别器对抗训练以逼近真实分布的生成模型         |
| VAE                        | 变分自编码器 | Variational<br>Autoencoder           | 以编码—解码结构与潜在变量近似分布的生成模型          |

| 术语/缩写           | 中文全称        | 英文全称                                                  | 简明释义                          |
|-----------------|-------------|-------------------------------------------------------|-------------------------------|
| Diffusion Model | 扩散模型        | Diffusion Model                                       | 以逐步加噪—去噪过程学习并生成数据的生成模型        |
| LLM             | 大语言模型       | Large Language Model                                  | 基于自回归预训练的大规模语言模型              |
| CTGAN           | 条件表格生成对抗网络  | Conditional Tabular GAN                               | 面向表格数据的条件 GAN 方法（Xu 等，2019）   |
| TVAE            | 表格变分自编码器    | Tabular VAE                                           | 面向表格数据的 VAE 变体                |
| TabDDPM         | 表格扩散模型      | Tabular DDPM                                          | 将扩散模型适配表格数据的生成方法              |
| GReaT           | 基于语言模型的表格生成 | Language Models are Realistic Tabular Data Generators | 以语言模型把表格行“翻译”为文本再生成的 LLM 合成路线 |
| SMOTE           | 少数类过采样      | Synthetic Minority Over-sampling                      | 以插值合成少数类样本的经典数据增强方            |

| 术语/缩写                | 中文全称  | 英文全称                 | 简明释义                               |
|----------------------|-------|----------------------|------------------------------------|
|                      |       | Technique            | 法                                  |
| Model Collapse       | 模型崩溃  | Model Collapse       | 以模型自身输出递归训练导致多样性与质量退化的现象           |
| Hyper-Synthetic Data | 超合成数据 | Hyper-Synthetic Data | Gartner（2025）提出的以仿真与智能体生成复杂环境数据的方向 |
| Data Masking         | 数据脱敏  | Data Masking         | 以掩码、泛化、置换等改造真实数据以降低识别风险            |
| Anonymization        | 匿名化   | Anonymization        | 使个体不可再识别的数据处理；国内监管下合成数据不当然视为匿名化    |
| Federated Learning   | 联邦学习  | Federated Learning   | 原始数据不出域的多方协同训练方法                   |

| 术语/缩写             | 中文全称    | 英文全称                       | 简明释义                        |
|-------------------|---------|----------------------------|-----------------------------|
| Privacy Computing | 隐私计算    | Privacy Computing          | 联邦学习、多方安全计算、可信执行环境等隐私保护技术统称 |
| TDM               | 测试数据管理  | Test Data Management       | 为开发测试环境提供合规、可用数据的管理工程能力     |
| TRL               | 技术就绪度   | Technology Readiness Level | 自 NASA 而来的 1—9 级工程就绪度评价     |
| Hype Cycle        | 技术成熟度曲线 | Gartner Hype Cycle         | Gartner 描述技术从炒作到成熟五阶段的框架    |
| JTBD              | 待办任务    | Jobs-to-be-Done            | 从用户目标而非技术功能出发识别场景的方法        |
| PoC               | 概念验证    | Proof of Concept           | 小范围验证技术与价值假设的项目形式           |
| 六维评估              | —       | —                          | 技术成熟度、                      |

| 术语/缩写 | 中文全称  | 英文全称                        | 简明释义                                                                                                        |
|-------|-------|-----------------------------|-------------------------------------------------------------------------------------------------------------|
|       |       |                             | 战略匹配度、<br>价值贡献度、<br>引入可行度、<br>战略紧迫度、<br>生态开放度六<br>维 1—5 分评<br>价                                             |
| 处置档位  | —     | —                           | 前沿技术储备<br>库四档结论：<br>提前布局 / 系<br>统论证 / 深入<br>研究 / 动态观<br>察                                                   |
| AUC   | 曲线下面积 | Area Under<br>the ROC Curve | 随机抽取一个<br>正样本与一个<br>负样本、模型<br>把正样本排在<br>前面的概率；<br>0.5 近似随<br>机、越接近 1<br>区分越强，衡<br>量模型整体排<br>序能力、与业<br>务阈值无关 |

| 术语/缩写 | 中文全称      | 英文全称                           | 简明释义                                                                |
|-------|-----------|--------------------------------|---------------------------------------------------------------------|
| KS    | 最大区分度统计量  | Kolmogorov - Smirnov statistic | 好客户与坏客户两组累计分布的最大差距，表示模型在最优切点处的最大区分强度；通常与 AUC 同向，比 AUC 更贴近业务阈值选择     |
| 召回率   | 查全率 / 灵敏度 | Recall / Sensitivity           | 全部真实正样本（如违约户、欺诈交易）中模型实际抓到的比例，用于衡量“抓坏人”的能力；只看召回会误伤正常客户，须与误报率 / 精确率权衡 |

### 附录三 参考文献

以下信源按正文引用顺序编号，同类信源（学术论文、Gartner 与市场机构、监管文件、我行材料）适当归组编排，并标注来源类型与核实状态。除注明者外均为公开可查证信源。

[1] Goodfellow, I., et al. Generative Adversarial Nets. NeurIPS 2014. arXiv:1406.2661.（学术论文，公开可查证）

[2] Kingma, D. P., Welling, M. Auto-Encoding Variational Bayes. ICLR 2014. arXiv:1312.6114.（学术论文，公开可查证）

[3] Ho, J., Jain, A., Abbeel, P. Denoising Diffusion Probabilistic Models. NeurIPS 2020. arXiv:2006.11239.（学术论文，公开可查证）

[4] Xu, L., Skoularidou, M., Cuesta-Infante, A., Veeramachaneni, K. Modeling Tabular Data Using Conditional GAN. NeurIPS 2019. arXiv:1907.00503.（学术论文，公开可查证）

[5] Kotelnikov, A., Baranchuk, D., Rubachev, I., Babenko, A. TabDDPM: Modelling Tabular Data with Diffusion Models. ICLR 2023. arXiv:2209.15421.（学术论文，公开可查证）

[6] Borisov, V., et al. Language Models Are Realistic Tabular Data Generators ( GReaT ) . arXiv:2210.06280, 2022. (学术论文, 公开可查证)

[7] Chawla, N. V., Bowyer, K. W., Hall, L. O., Kegelmeyer, W. P. SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16:321 - 357, 2002. (学术论文, 公开可查证)

[8] Rubin, D. B. Multiple Imputation for Nonresponse in Surveys. John Wiley & Sons, 1987. (学术专著, 公开可查证)

[9] Benedetto, G., Stinson, M., Abowd, J. The Creation and Use of the SIPP Synthetic Beta (SSB) . U.S. Census Bureau. ( 公 开 可 查 证 ; <https://www.census.gov/programs-surveys/sipp/>)

[10] Patki, N., Wedge, R., Veeramachaneni, K. The Synthetic Data Vault. IEEE DSAA, 2016. (学术论文, 公开可查证)

[11] Dwork, C. Differential Privacy. ICALP 2006. (学术论文, 公开可查证)

[12] Shokri, R., Stronati, M., Song, C., Shmatikov, V. Membership Inference Attacks Against Machine Learning Models. IEEE S&P 2017. (学术论文, 公开可查证)

[13] Fredrikson, M., Jha, S., Ristenpart, T. Model Inversion Attacks That Exploit Confidence Information and Basic Countermeasures. USENIX Security 2015. (学术论文, 公开可查证)

[14] Stadler, T., Oprisanu, B., Troncoso, C. Synthetic Data - Anonymisation Groundhog Day. USENIX Security 2022. (学术论文, 公开可查证)

[15] Shumailov, I., et al. AI Models Collapse When Trained on Recursively Generated Data. Nature, 631:755 - 759, 2024. (学术论文, 公开可查证)

[16] Zhang, J., Cormode, G., Procopiuc, C. M., Srivastava, D., Xiao, X. PrivBayes: Private Data Release via Bayesian Networks. PVLDB, 2017. (学术论文, 公开可查证)

[17] Fiore, U., De Santis, A., Perla, F., Zanetti, P., Palmieri, F. Using Generative Adversarial Networks for Improving Credit Card Fraud Detection. Information Sciences, 2019. (学术论文, 公开可查证)

[18] Gartner. Top Trends in Data and Analytics, 2022. 2022-03-11 (Rita Sallam, Ted Friedman, et al.). (Gartner 会员报告；标题与日期经第三方授权引载页核实)

[19] MIT Sloan Management Review. What Is Synthetic Data—and How Can It Help You Competitively? 2023-01-23. (行业媒体；转引 Gartner 关于“到 2024 年 60% 的 AI 与分析数据为合成生成”的估算口径) <https://mitsloan.mit.edu/ideas-made-to-matter/what-synthetic-data-and-how-can-it-help-you-competitively>

[20] Gartner. What Generative AI Means for Business. (Gartner 官网公开页面；含“到 2026 年 75% 的企业将使用生成式 AI 创建合成客户数据，2023 年不足 5%”的预测；页面持续更新)

[21] Communications of the ACM. AI Goes Synthetic to Get Real. 2026-01-23. (行业权威媒体；转引 Gartner 数据) <https://cacm.acm.org/news/ai-goes-synthetic-to-get-real>

[22] Gartner. AI Services Disruptor: Hyper-Synthetic Data. 2025-08-18. (Gartner 会员文档；条目与摘要经公开检索核实)

[23] TechCrunch. Nvidia Reportedly Acquires Synthetic Data Startup Gretel. 2025-03-19. (权威科技媒

体 ) <https://techcrunch.com/2025/03/19/nvidia-reportedly-acquires-synthetic-data-startup-gretel/>

[24] WIRED. Nvidia Bets Big on Synthetic Data. 2025-03-19. (权威科技媒体; 报道收购金额超 3.2 亿美元)  
<https://www.wired.com/story/nvidia-gretel-acquisition-synthetic-training-data/>

[25] SAS ( via PR Newswire ) . SAS Acquires Hazy Synthetic Data Software to Boost Generative AI Capabilities. 2024-11-12. (厂商官方发布)

[26] Grand View Research. Synthetic Data Generation Market Size, Share & Trends Report. (公开报告摘要页; 2023 年 2.183 亿美元→2030 年 17.88 亿美元, CAGR 35.3%, 2024 — 2030 )  
<https://www.grandviewresearch.com/industry-analysis/synthetic-data-generation-market-report>

[27] Mordor Intelligence. Synthetic Data Market Size, Share, Trends & Research Report, 2031. 2026-01-29. (公开报告摘要页; 2025 年 5.10 亿→2031 年 36.7 亿美元, CAGR 38.96% )  
<https://www.mordorintelligence.com/industry-reports/synthetic-data-market>

[28] Fortune Business Insights. Synthetic Data Generation Market Forecast Analysis, 2034. 2026-08-17.

（公开报告摘要页；2026 年 7.91 亿→2034 年 69.05 亿美元，CAGR 31.10%）  
<https://www.fortunebusinessinsights.com/synthetic-data-generation-market-108433>

[29] Precedence Research. Synthetic Data Generation Market Report. 2026-08-25. （公开报告摘要页；口径偏宽，2025 年 5.85 亿 → 2035 年 107.8 亿美元）  
<https://www.precedenceresearch.com/synthetic-data-generation-market>

[30] Research and Markets. Synthetic Data Market Report 2026. （公开报告摘要页；2026 年 9.20 亿→2030 年 30.20 亿美元，CAGR 34.5%）

[31] Market Research Future. Synthetic Data Generation Market Report. 2026-08-24. （公开报告摘要页；口径最宽，2025 年 7.71 亿→2035 年 346.2 亿美元，CAGR 46.3%）

[32] Nationwide Technology (Medium) . Hazy: Synthetic Data to Fuel Rapid Innovation. 2020-11-19.  
（机构官方技术博客，公开可查证）

[33] Hazy (厂商渠道披露). Nationwide 案例: 合成数据将外部创新伙伴评估周期由 6 个月缩短至 3 天. (厂商口径, 未获独立第三方验证)

[34] J.P. Morgan AI Research. Synthetic Data 研究项目与公开数据集页面 .  
<https://www.jpmorganchase.com/research/ai>. (机构官方来源, 公开可查证)

[35] SynDEc: A Synthetic Data Ecosystem. Electronic Markets (Springer), 2025-01-25. (同行评审期刊; 与菲律宾 UnionBank 等两家银行联合开展设计研究)

[36] Global Banking Monitor. Riyadh Bank's Jeel Signs MoU with zypl.ai to Enhance Digital Innovation. 2025-07-15. (行业媒体, 公开可查证)

[37] 国家金融监督管理总局. 银行保险机构数据安全管理办法. 2024 年 12 月印发. (公开可查证)  
[https://www.gov.cn/zhengce/zhengceku/202412/content\\_6995081.htm](https://www.gov.cn/zhengce/zhengceku/202412/content_6995081.htm)

[38] 全国人大常委会. 中华人民共和国个人信息保护法. 2021-08-20 通过, 2021-11-01 施行. (公开可查证)  
[https://www.cac.gov.cn/2021-08/20/c\\_1631050028355286.htm](https://www.cac.gov.cn/2021-08/20/c_1631050028355286.htm)

[39] 全国人大常委会. 中华人民共和国数据安全法. 2021-06-10 通过, 2021-09-01 施行. (公开可查证)  
[https://www.cac.gov.cn/2021-06/11/c\\_1624994566919140.htm](https://www.cac.gov.cn/2021-06/11/c_1624994566919140.htm)

[40] 国务院. 网络数据安全条例 (国务院令 第 790 号). 2024 年公布. (公开可查证)  
[https://www.gov.cn/gongbao/2024/issue\\_11646/202410/content\\_6980863.html](https://www.gov.cn/gongbao/2024/issue_11646/202410/content_6980863.html)

[41] 国家互联网信息办公室等四部门. 互联网信息服务算法推荐管理规定. 2022-03-01 施行. (公开可查证)  
[https://www.cac.gov.cn/2022-01/04/c\\_1642894606364259.htm](https://www.cac.gov.cn/2022-01/04/c_1642894606364259.htm)

[42] 国家互联网信息办公室等. 互联网信息服务深度合成管理规定. 2023-01-10 施行. (公开可查证)

[43] 国家金融监督管理总局. 关于银行业保险业人工智能安全开发应用的指导意见 (金发〔2026〕8 号). 2026-06-18. (公开可查证)  
<https://www.nfra.gov.cn/cn/view/pages/ItemDetail.html?docId=1261784>

[44] 中国人民银行. 征信业务管理办法 (中国人民银行令〔2021〕第 4 号). (公开可查证)

[45] 中国人民银行. 金融领域科技伦理指引 (JR/T 0258—2022). 2022-10 发布实施. (公开可查证; 标准备案信息见全国标准信息公共服务平台)

[46] 中共中央、国务院. 关于构建数据基础制度更好发挥数据要素作用的意见 (“数据二十条”). 2022-12 发布. (公开可查证)

[47] 上海浦东发展银行. 2025 年年度报告 (2026-03-31); 2026 年上半年主要经营情况公告 (2026-07-20). (我行定期报告, 公开可查证)  
[https://static.sse.com.cn/disclosure/listedinfo/announcement/c/new/2026-03-31/600000\\_20260331\\_ZWFN.pdf](https://static.sse.com.cn/disclosure/listedinfo/announcement/c/new/2026-03-31/600000_20260331_ZWFN.pdf)

[48] Gartner. Executive Briefing on Emerging Technology: Synthetic Data. 2024-07-24. (Gartner 会员文档; 条目与摘要经公开检索核实)

[49] IBM. InfoSphere Optim 测试数据管理解决方案官方说明. (厂商官方来源; 用作银行测试数据管理工程实践参照)

[50] 弗若斯特沙利文 (Frost & Sullivan) 中国. 2025 年中国合成数据解决方案发展洞察 (白皮书). 2025-09. (沙利文中国官网发布 (含英文版发布页); 公开转载见搜狐、大数跨境 (10100) 等平台. 该报告属行业/企业定制化白皮书业务范畴并含厂商实践案例, 宜按委托类行业研究引用, 不宜视

为完全独立的第三方市场数据；原版 42 页 PDF 需经沙利文或其转载渠道获取）

[51] Xin, H., Guo, D., Shao, Z., Ren, Z. Z., Zhu, Q., Liu, B., Ruan, C., Li, W., Liang, X. DeepSeek-Prover: Advancing Theorem Proving in LLMs through Large-Scale Synthetic Data. arXiv:2405.14333, 2024-05-23. （学术论文，公开可查证；约 800 万条 Lean 4 合成形式证明语句微调 DeepSeekMath-7B, miniF2F 整句生成通过率约 50%、超过此前最优 41.0%）

[52] Zhao, Y., Zhang, J. Does Training with Synthetic Data Truly Protect Privacy? ICLR 2025. arXiv:2502.12976, 2025. （学术论文，公开可查证；对核心集选择、数据集蒸馏、无数据知识蒸馏与扩散模型合成四类范式检验后指出：无差分隐私保证的合成数据训练未必保护隐私，易产生“虚假的安全感”）

[53] Qin, Z., Dong, Q., et al. (Microsoft) . Scaling Laws of Synthetic Data for Language Models. arXiv:2503.19551, 2025. （学术论文，公开可查证；SYNTH-LLM：合成语料在大模型预训练中服从可预测缩放规律，性能增益在约 300B token 后趋缓）

[54] Ben Melech Stan, G., Aflalo, E., Madasu, A., Lal, V., Howard, P. (Intel Labs) . Learning from

Reasoning Failures via Synthetic Data Generation.

arXiv:2504.14523, 2025. (学术论文, 公开可查证; 以“分

析弱模型推理缺陷→定向生成合成样本→自动质检过滤”构造

55.3 万条多模态指令数据)