

前沿技术专题研究报告——合成数据（ Synthetic Data）

面向银行科技条线的技术成熟度评估与处置建议

Technical Maturity Assessment & Strategic Recommendation

V4.3 / 2026-09

汇报对象：银行科技条线决策层

汇报人：前沿课题研究组

目录 CONTENTS

- 01 执行摘要与核心结论
- 02 背景与银行数据供给痛点
- 03 技术解析与成熟度评级
- 04 应用场景与价值实证
- 05 风险与合规红线
- 06 市场格局与竞争生态
- 07 战略匹配与六维评级
- 08 分阶段实施路线图

执行摘要与核心结论

技术成熟度 3 分 | 战略匹配 3 分 | 价值贡献 3 分 | 处置档位：深入研究

执行摘要：六维评级一览（雷达图）

各维度分值与覆盖要点

合成数据六维评估（1—5分；结论按处置档位组合判据推导，非加权平均）




图 1.1 合成数据六维评估雷达（1—5 分）

关键读法

- 六维均为 3 分，仅「生态开放度」为 4 分——技术不成熟是主要短板，生态可缓解
- 处置档位为「深入研究（研究层）」，而非「试点」或「规模引入」
- 建议先以小颗粒度 POC 沉淀方法论，再依窗口期信号复评升级

核心结论与价值定位

决策层最关心的 6 条结论

- 围绕「能不能用、何处用、谁来用、风险谁担」四条主线得出以下结论：
 - **结论一：**技术成熟度为 **3 分**——通用工具链成熟、银行表格合成域仍处有限试点、标准未成
 - **结论二：**银行场景优先级为「**测试数据生成 > 风控/反欺诈增强 > 数据共享 > 大模型语料**」
 - **结论三：****合成数据并不天然隐私安全**——不得默认「合成即匿名」
 - **结论四：****风险与合规**是首要约束——个人信息保护法、数据安全法、金发〔2026〕8 号构成合规红线
 - **结论五：****同业以研究/试点为主**，尚未规模化；先验证者可沉淀评测与治理先发能力
 - **结论六：**处置档位建议「**深入研究（研究层）**」——以可中止的 POC 控制下行风险
- 数据来源：执行摘要章节。处置档位推导依据六维评级组合判定，非加权平均。

背景与银行数据供给痛点

数据供给四类失效机制 + 合成数据为何在当下重新被关注

合成数据为何在当下重新受到关注

技术、产业与监管三重叠加

- 生成式 AI 浪潮 + 数据合规收紧 + 数据资产化诉求 三股力量同时到达。
- **生成式 AI 语料饥渴**：LLM 训练/评测对高质量、结构化样本的需求外溢到行业数据集
- **数据合规收紧**：个人信息保护法、数据安全法、金发〔2026〕8 号对真实数据使用持续加压
- **数据资产化**：银行把数据视为「生产要素」——必须给出可流转、可共享、可审计的供给方案
- **隐私计算成熟**：联邦学习、可信执行环境为合成数据提供「协作分发」通道
- **开源工具成熟**：SDV/CTGAN/TVAE 等进入 GitHub Trending，工程化门槛显著下降
- 判断：技术、政策、业务三股力量同步到达，未来 3—5 年是关键窗口期。

银行数据供给的四类失效机制

按对模型迭代与上线的影响严重程度排序（5=最严重）

- 合成数据解决的是「**生成新的可用数据**」，并不替代脱敏与隐私计算，而是与之**互补**。
- **[1] 采集慢、标注贵**
 - 数据资产「**有但用不起**」——结构化标注成本随合规要求指数上升。
- **严重度 3.5 / 5**
- **[2] 长尾样本稀缺**
 - 欺诈、电信诈骗、洗钱等**高价值场景样本不足**，模型难迭代。
- **严重度 5 / 5（最高）**
- **[3] 脱敏破坏可用性**
 - 传统脱敏使**关联结构与统计特征失真**，训练出来的模型可解释性下降。
- **严重度 4 / 5**
- **[4] 数据流转受限**
 - 数据**出域即合规事件**——跨条线、跨法人、跨境的流通效率低。
- **严重度 3 / 5**

技术解析与成熟度评级

定义 / 形态 / 技术路线 / 质量三角 / 成熟度 3 分

技术定义与三种数据形态

合成数据的边界与三种形态对比

三种形态并非互斥；本行 POC 中可同时采用部分合成+混合合成。

形态	数据来源	典型用途	代表场景
完全合成 (Fully Synthetic)	不依赖真实数据，全模型生成	概念验证、极端情景仿真	压力测试、对抗样本
部分合成 (Partially Synthetic)	对真实数据中部分敏感字段做替换	保留关联结构又降低识别风险	风控增强、长尾样本增广
混合合成 (Hybrid)	真实+合成按比例混合	训练集扩增、跨域数据共享	联合建模、对外数据评估

四类主流技术路线横向对比（满分 5）


7 维度评分：银行场景以 GAN+扩散组合为主，LLM 驱动受合规约束较大

没有「最好」的技术，只有「最适配」的技术——选型应与目标场景的「保真度/隐私/可控性」三角位置匹配。

维度	GAN (CTGAN)	VAE (TVAE)	扩散 (TabDDPM)	LLM (GReaT)
生成质量	3.5	3.0	5.0	4.0
训练稳定性	2.0	4.0	4.0	4.0
生成速度	4.5	4.5	2.0	2.0
可控性	4.0	3.0	4.0	5.0
隐私安全性	2.0	3.0	2.0	2.5
低成本算力	4.0	5.0	2.0	2.0
银行场景成熟度	4.0	2.5	3.0	3.0

质量三维评价与「不可能三角」

差分隐私预算 ϵ 、去标识程度等参数决定三维折中位置



差分隐私预算 ϵ 、去标识程度等参数，决定本银行每次合成的“三维折中位置”（可审计参数）

图 3.1 保真度 / 效用 / 隐私 三维权衡示意

读图要点

- 提升任意两者，通常以第三者为代价——没有「三者全优」的最优解
- 可审计参数： ϵ （差分隐私预算）、去标识程度决定本次合成的三角位置
- POC 应预设每个任务的折中点，并记录审计依据

必须澄清：合成数据并不天然隐私安全

脱敏 / 合成 / 隐私计算——互补关系而非替代

关系边界：脱敏解决“降低真实数据识别风险”，合成数据解决“生成新的可用数据”，隐私计算解决“数据不出域时如何协同”——互补而非替代




图 3.2 真实数据 / 脱敏 / 合成 / 隐私计算 关系边界

四件事各司其职

- **脱敏/匿名化**：改造真实数据，降低识别风险
- **合成数据**：生成层——学习真实分布后生成新的可用数据
- **行内受限使用**：模型训练、开发测试可走脱敏/合成路径
- **对外受限提供**：须走共享审批；可叠加**隐私计算**实现「数据不出域」协同

技术成熟度评级：3 分

四条证据均不支持突破 3 分

- 通用工具链较成熟，但银行表格合成域仍处有限试点，标准未成——综合评级 3 分。
- **Gartner 定位**：2022 年列入顶级趋势，2024—2025 年仍以「新兴技术/颠覆者」框架跟踪，未见主流生产成熟区
- **TRL 分域**：图像/3D 仿真 TRL 7—8（生产可用）；金融表格合成 TRL 5—6；LLM 驱动合成 TRL 4—5
- **生产案例**：通用工具成熟（SDV、Gretel、Mostly、Tonic），银行侧**多为试点与研究，无公开生产级量化案例群**
- **标准化程度**：**缺乏生成质量与隐私评估的统一标准**——评测多依赖社区基准与厂商自评
- 评级原则：短板取下。短板 = 标准化与银行侧生产案例缺失。

应用场景与价值实证

五场景矩阵 + 四大场景详解 + 效益测算 + 同业案例

5 大应用场景矩阵（气泡图）

横轴 = 技术就绪度，纵轴 = 价值清晰度，气泡大小 = 优先级




图 4.1 银行合成数据 5 大应用场景价值—就绪度分布

5 大场景速览

- 场景 1 — 测试数据生成：高价值+高就绪，POC 之首
- 场景 2 — 风控训练数据增强、场景 3 — 反欺诈与异常检测：高价值但就绪待验证，POC 之二（合并评估）
- 场景 4 — 数据共享/隐私保护、场景 5 — 大模型语料合成：方向合理但证据有限，跟踪评估

场景 1 + 2 详解：POC 优先两个场景

场景 1 = 测试数据 (POC 之首) , 场景 2 = 风控增强 (POC 之二)

场景 1 — 测试数据生成与系统验证

- **痛点**: 开发/回归/压力测试依赖人工造数; 真实数据下移受限
- **价值**: 行业经验表明**测试准备周期可缩短 20%—60%**
- **形态**: **完全合成**——可在云端测试环境大量生成、销毁即净
- **POC 路径**: 选定 1—2 个核心系统 (信贷、交易监控) , 覆盖三个月回归用例

场景 2 — 风控模型训练数据增强

- **痛点**: 违约、欺诈、流失长尾样本不足; 新客群无历史
- **价值**: 学术证据支持长尾召回率提升 5%—15% (AUC 持平)
- **形态**: **部分合成 + 混合合成**——保留关联结构同时扩增长尾
- **POC 路径**: 以信用卡反欺诈为切入点, 做「真实 vs 合成+真实」对照实验

场景 3-5 跟踪评估：反欺诈、数据共享、大模型语料

不进入本期 POC，但需保留跟踪评估窗口

- 以下三个场景**价值清晰度或技术就绪度**待进一步验证，**不进入本期 POC**，但保留跟踪评估窗口。
- **[3] 反欺诈与异常检测**
 - 与场景 2 同属风控族；可在场景 2 POC 中**合并评估**，避免重复投入。
- **[4] 数据共享 / 隐私保护**
 - 行内部门/子公司/外部协作真实数据流转受限；合成数据是**方向合理、证据有限**的可选路径。
- **[5] 大模型语料与文本合成**
 - 垂类模型训练/评测语料不足；合成可补充，但需**叠加差分隐私**并控制记忆风险。
- **[!] 应用边界（必须澄清）**
 - 合成数据**不得**用于监管报送、账务/生产数据——报送与生产**仍以真实数据为准**；**不主张**用于规避征信、客户隐私等合规要求。

效益测算（示意口径，非收益承诺）

保守 / 中性 / 乐观 三档（百分比类指标）

本测算仅作**决策方向参考**，不构成收益承诺；最终价值以 POC 实测为准。

指标	保守	中性	乐观
测试周期缩短	20%	40%	60%
长尾识别率改善	0%	10%	20%
数据获取成本下降	5%	12%	20%
外部共享流程缩短	0%	50%	90%

国内外同业落地案例

阶段：C 研究层 → B 试点前 → A 试点向生产

- 全球银行业**尚未出现公开生产级量化案例群**——本行应**跟踪而不押注**。
- **[C]** JPMorgan Chase（美国）
 - 金融合成数据集与方法研究，**公开发布供学界与产业使用**——贡献开源基准。
- **[A]** Nationwide（英国）
 - 合成数据支持**外部创新伙伴数据评估与共享**——流程 6 个月→3 天（厂商口径，未独立验证）。
- **[C]** UnionBank（菲律宾）
 - 参与「合成数据共享生态（SynDEc）」设计研究——**验证金融业共享框架**。
- **[B]** Riyadh Bank（沙特）
 - 与 zypl.ai 签 MoU——**尚无公开量化结果**，仅前期合作。
- **[—]** 国内银行（中国大陆）
 - **未检索到银行官方披露的生产级应用**——本行仍处于窗口期。

风险与合规红线

监管映射 + 风险清单 (概率 × 影响)


监管合规要求映射（风险等级）

等级越高 = 合规约束越强 = 需前置审批

- 《个人信息保护法》与「金发〔2026〕8号」构成**两条高风险红线**——引入前必须落实安全评估。
- [5] 《个人信息保护法》
 - 全行红线：含个人信息的数据处理全链路审计；**合成数据需在去标识基础上做 DPIA。**
- [4] 《数据安全法》
 - 数据分类分级 + 重要数据出境安全评估；合成数据共享触发该法多项义务。
- [4] 《银行保险数据安全管理办法》
 - 客户信息**不出行**为默认；脱敏与合成**仅作为受控例外**。
- [4] 深度合成 AI 管理规定
 - 合成内容需**显著标识**；模型服务备案、训练数据来源合法。
- [5] 金发〔2026〕8号（金融领域 AI 指引）
 - 金融 AI 应用**事前评估、过程审计、结果可解释**——对生成式 AI 重点关注。
- [3] 《征信业务管理办法》
 - 若合成数据用于类征信模型训练，**需穿透审查底层数据合法性**。

风险清单（概率 × 影响 气泡图）

X = 发生概率（1=低, 5=高），Y = 业务影响（1=低, 5=高）



象限解读

- 右上角（高×高）= 重点防御：隐私泄露、监管认可、保真度、偏差、人才缺口
- 中部（中×中）= 常规管控：模式崩溃、血缘断裂、供应商
- 应对原则：先解右上角再扩展 POC；隐私与合规为前置项

市场格局与竞争生态

全球市场规模 + 厂商/开源生态 + 行业五力

合成数据行业 Porter 五力结构

银行作为购买者议价能力偏强，替代品威胁偏高

合成数据行业 Porter 五力结构示意图（自绘）




图 6.1 合成数据行业五力结构示意图（自绘）

****读图要点****

- **潜在进入者**：高（开源门槛低、云大厂切入）——生态风险敞口上升
- **供应商**：中等（算力集中、算法开源）——可缓解
- **购买者**：**中等偏强**——银行议价能力强、实施稀缺
- **替代品**：**中等偏高**（脱敏/隐私计算可替代）——本行应取合成+互补组合

全球市场规模：多来源交叉验证（USD 十亿）

Gartner 预判与产业并购信号一致：3—5 年关键窗口

四家机构口径**方向一致、量级存在差异**——应以「区间+方向」而非「单点数字」决策。




图 6.2 合成数据市场规模预测（四机构对照）

****读图要点****

- **2026 年区间：** 7.9—9.2（USD 十亿）——口径差异约 $\pm 10\%$
- **2030 年区间：** 17.9—30.2——**方向上行、增速分歧**
- **行业共识：** 年复合增长 **30%—40%**——3—5 年关键窗口期

厂商与开源生态格局（成熟度评分）

并购整合者 > 开源生态 > 专业厂商 > 国内参与者

- 建议**优先 SDV/DataCebo 基线 + 选择性厂商能力叠加**，避免单一技术路线绑定。
- **[5] NVIDIA-Gretel**（并购整合）
 - GPU 算力栈 + 合成数据平台；**生态最完整**，但需关注供应商锁定与数据出域。
- **[5] SAS-Hazy**（企业级）
 - 金融行业 know-how 沉淀深；**项目实施成本高**——预算口径需提前评估。
- **[5] SDV / DataCebo**（开源基线）
 - MIT/Apache 协议；**首推作为内部基线**，扩展性最好、可控性最强。
- **[4] ydata-synthetic**（开源）
 - 支持多模型与质量评估，**适合 POC 阶段横向对照**。
- **[4] Mostly / Tonic / YData**（专业厂商）
 - API 化交付、**集成速度快**；隐私保护与合规审计能力参差。
- **[3] 国内厂商**（国产化路径）
 - 成熟度不一，**核心系统优先本土可控**；要求国产化时再启动选型评估。

战略匹配与六维评级

SWOT + 六维雷达 + 处置档位推导

战略匹配度与 SWOT 分析

本行禀赋 × 外部环境的策略转化

优势、劣势、威胁、机会四象限组合——支持「深入研究（研究层）」的处置档位结论。

S 优势 Strengths

数据资产规模大、治理体系较完善；已有数据中台、AI 平台与模型风险管理流程可承接；风控、研发测试场景痛点真实且可量化。SO 策略：以开源工具在既有平台做低成本 POC，把「数据资产」转化为「数据供给能力」。

W 劣势 Weaknesses

生成模型工程与隐私审计人才不足；合成数据质量评估方法与评测基线空白；真实数据血缘与授权管理仍需补课。WO 策略：借 POC 沉淀方法论与评测基线，同步补数据就绪度短板。

O 机会 Opportunities

生成式 AI 与大模型战略叠加，数据供给需求上升；**开源与商用工具成熟**、生态开放度高；同业尚未规模化，先验证者可沉淀方法论。ST 策略：以研究层定位抢窗口期建立评测与治理先发能力，**不押注平台规模**。

T 威胁 Threats

合成数据**不被监管认可为「匿名」**，合规路径不确定；**脱敏增强、隐私计算与数据治理改进可部分替代**；技术路线快速迭代存在沉没成本风险；AI 资源优先投向垂类大模型与智能体。WT 策略：不建独立平台、不押注单一技术路线，以可中止的 POC 控制下行风险。

六维评级汇总（雷达图）

生态开放度 4 分，其余 5 项均为 3 分




图 7.1 六维评估（结论按处置档位组合推导，非加权平均）

关键读法

- **短板维度 = 技术成熟度**——通用工具链成熟，但**银行表格合成域仍处有限试点**
- **唯一 4 分 = 生态开放度**——开源为主、多厂商可选、国产化路径存在
- **价值贡献度**审慎取 3：测试数据可量化，风控增强待行内实测

处置档位推导：深入研究（研究层）

由六维评级组合推导，非简单加权

- 处置档位共四档：观察 / 研究 / 试点 / 规模引入。本技术位列第二档「研究层」。
- ▪ **推导逻辑**：短板维度（技术成熟度 3 分）+ 战略匹配（3 分）+ 价值贡献（3 分）+ 紧迫度（3 分）——四维均为 3 分，仅生态开放度为 4 分
- ▪ **结论**：处置档位 = 「**深入研究（研究层）**」——可组件化增量引入，按季度复评
- ▪ **窗口期**：**3—5 年关键窗口**——Gartner 预判与产业并购信号明确
- ▪ **复评触发**：每半年评估一次，由 Gartner 信号、监管动态、同业进展、本行实测四源数据驱动
- 处置档位门槛对照见下页。

处置档位门槛对照（按最低门槛决定档位）

技术成熟度、战略匹配、价值贡献、引入可行性取短板

档位判定不取平均分而取短板——任一维度未达门槛则不得进入下一档位。

档位 1 观察

技术尚未成型，本行场景未识别——保持跟踪评估

0—1 分门槛

档位 2 **深入研究（研究层）**

技术有限成熟 + 本行有可验证场景——以可中止 POC 沉淀方法论

2—3 分门槛

档位 3 试点

技术基本成熟 + 价值清晰 + 风险可控——双场景 POC + 治理并行

3—4 分门槛

档位 4 规模引入

技术成熟 + 标准统一 + 监管认可——组件化嵌入生产流程

4—5 分门槛

分阶段实施路线图

0—36 个月，三阶段推进 + 复评门槛

分阶段实施路线图（0—36 个月）

三阶段 + 两次处置档位复评 + 一次组件上线审计




图 8.1 合成数据研究层路线图（0—36 个月）

关键节点

- 6 个月：第一阶段 go/no-go——评估双场景 POC 结果
- 18 个月：试点决策——升级至「试点」或止损
- 36 个月：组件上线审计——年度复评

启动前提与 Build vs Buy

POC 启动前必须具备的 6 项前提

启动前提（缺一不可）

- **数据就绪度评估**：对 POC 范围数据完成**分类分级与授权链条核查**
- **评测基线先行**：明确「真实 vs 真实+合成」对照指标，避免先做后评
- **最小可行治理**：合成数据**不得主张匿名化**，须纳入数据安全评估与外包管理
- **人才补短板**：至少 1 名生成模型工程师 + 1 名隐私审计人员，可外包但需内部联络人

Build vs Buy 决策倾向

- **首选开源基线**：SDV / DataCebo + CTGAN / TabDDPM，本地化部署，**PoC 首选**
- **选择性叠加商用**：Mostly / Tonic 等用于**评估基线对照**，不作生产依赖
- **国内参与者**：翼方健数、富数科技、洞见科技——作为**隐私计算 + 合成**协同候选
- **避坑**：**不押注单一厂商、不建独立平台**——保持可中止与可替换

结论与建议

决策层五项行动建议

- 技术成熟度 3 分、生态开放度 4 分——窗口期 3—5 年。
- **建议一：处置档位定为「深入研究（研究层）」**——以可中止的 POC 控制下行风险
- **建议二：POC 之首 = 测试数据生成（行业验证充分、风险较低）；POC 之二 = 风控/反欺诈增强（合并评估）**
- **建议三：不建独立平台、不押注单一技术路线**——以 SDV 开源基线 + 选择性厂商能力叠加
- **建议四：合规先行**——合成数据不主张匿名化，必须纳入数据安全评估与外包管理
- **建议五：每半年复评一次**——由 Gartner 信号、监管动态、同业进展、本行实测四源驱动
- 本结论不替代行内独立技术评审与合规审批；具体技术选型与业务接入方案以 POC 实测结果为准。

谢谢 THANK YOU