

人工智能安全平台 (AISP / AI TRiSM)

前沿技术专题研究报告

ZT018 · 储备库专题 · 信息采集截至 2026-08-17

- 人工智能安全平台（AISP，Gartner称AI TRiSM）是AI监管趋严与智能体规模化落地共同倒逼出的"必答题",
- 而非可选项。威胁侧，Gartner已将提示注入与深度伪造并列为2026年安全负责人须紧急改进的头部威胁[1,
- 2]；市场侧，2024—2025年间五起标志性并购（Palo Alto Networks收购Protect AI、
- Cisco收购Robust Intelligence、Check Point收购Lakera、

核心研判与处置建议

- 核心判断：AISP是本行001智能体、002 AI原生应用架构、017智能体互操作协议规模化落地的前置护栏，
- 具有强制属性（监管与风险倒逼）而非单纯效率工具属性。建议维持"论证层"定档，以AI资产台账与试点场景护栏POC作为先行动作即刻启动，
- 论证阶段与001智能体治理合并立项，用6—9个月完成能力缺口评估、双路径POC与AISP能力蓝图，形成本行AI安全的统一护栏底座。

- 在生成式AI与智能体进入生产环境之前，安全能力建设依赖两条相对独立的路径：一条是传统应用/API安全（WAF、API网关、DLP数据防泄漏、IAM身份与访问管理），另一条是传统模型风险管理（面向信贷评分、反欺诈等判别式模型的周期性验证、回溯测试与上线审批）。这两条路径在大模型与智能体场景下同时暴露出结构性缺陷，
- 是AISP作为独立技术品类出现的根本原因。

- 新加坡银行公会（ABS）联合星展银行（DBS）、华侨银行（OCBC）、大华银行（UOB）等10家主要银行机构及新加坡金融管理局（MAS），
- 于2025年5月发布《生成式AI护栏手册》，是目前公开可查、由银行业集体沉淀的最系统化AISP方法论之一[18]。
- 手册基于超过30个真实业务场景，覆盖文件提取/摘要、代码生成、客户服务等7大应用类别，系统梳理了14类关键风险（含幻觉/编造、
- 模型准确性不足、有毒/冒犯性输出、代表性偏见、治理缺失、人工监督不足等）及对应的9类护栏。

结语

- 持续跟踪技术演进与政策变化
- 以先行动作验证价值、控制风险
- 动态更新储备库定档与评估